



UNIVERSIDADE FEDERAL DO CEARÁ
CENTRO DE TECNOLOGIA
DEPARTAMENTO DE ENGENHARIA DE TELEINFORMÁTICA
CURSO DE GRADUAÇÃO EM ENGENHARIA DE COMPUTAÇÃO

JOSÉ FERREIRA LESSA, MATHEUS ROCHA GOMES DA SILVA

**AQUISIÇÃO DE BIOSINAIS PARA RECONHECIMENTO DE PADRÕES: PIPELINE
COMPLETO COM O DATASET PTB-XL**

FORTALEZA

2026

JOSÉ FERREIRA LESSA, MATHEUS ROCHA GOMES DA SILVA

AQUISIÇÃO DE BIOSSINAIS PARA RECONHECIMENTO DE PADRÕES: PIPELINE
COMPLETO COM O DATASET PTB-XL

Trabalho da cadeira de Aquisição de Biossinais apresentado ao Curso de Graduação em Engenharia de Computação do Centro de Tecnologia da Universidade Federal do Ceará, como requisito parcial à obtenção do grau de bacharel em Engenharia de Computação.

Orientador: Prof. Dr. Victor Hugo C. de Albuquerque

FORTALEZA

2026

RESUMO

Este trabalho apresenta o desenvolvimento de um pipeline completo de aquisição e preparação de biossinais eletrocardiográficos para aplicação de técnicas de Reconhecimento de Padrões (RP). Utilizando o dataset público PTB-XL, composto por 21.799 registros de ECG de 12 derivações com anotações diagnósticas distribuídas em cinco superclasses (NORM, MI, STTC, CD, HYP), foram implementadas dez etapas sequenciais: (i) aquisição e inspeção dos sinais brutos; (ii) avaliação objetiva da qualidade por meio de métricas *Signal Quality Index* / Índice de Qualidade do Sinal (SQI); (iii) análise estatística descritiva e de normalidade; (iv) filtragem digital e remoção de artefatos; (v) segmentação híbrida em nível de registro e de batimento individual; (vi) extração de atributos nos domínios do tempo, frequência, morfologia, tempo-frequência e não-linear; (vii) engenharia de features com criação de atributos de segunda ordem e normalização robusta; (viii) redução de dimensionalidade por *Principal Component Analysis* / Análise de Componentes Principais (PCA); (ix) seleção formal de atributos por métodos *filter*, *wrapper* e *embedded*; e (x) validação estatística do dataset final, com remoção de multicolinearidade residual e resultando em 21 atributos com alta separabilidade entre classes. Todas as etapas foram implementadas com rigoroso controle de data leakage, utilizando exclusivamente os dados de treinamento (folds 1–8) para o ajuste de parâmetros. O dataset final (`dataset_final_validado.parquet`) encontra-se pronto para entrada em classificadores de RP.

Palavras-chave: Eletrocardiograma. Biossinais. Reconhecimento de padrões. Extração de atributos. PTB-XL. Aprendizado de máquina.

ABSTRACT

This work presents the development of a complete acquisition and preparation pipeline for electrocardiographic biosignals aimed at Pattern Recognition (PR) techniques. Using the public PTB-XL dataset — comprising 21,799 12-lead ECG records annotated across five diagnostic superclasses (NORM, MI, STTC, CD, HYP) — ten sequential stages were implemented: (i) raw signal acquisition and inspection; (ii) objective signal quality assessment via SQI metrics; (iii) descriptive and normality statistical analysis; (iv) digital filtering and artifact removal; (v) hybrid segmentation at the record and individual heartbeat levels; (vi) feature extraction across the time, frequency, morphology, time-frequency and nonlinear domains; (vii) feature engineering with second-order attributes and robust normalization; (viii) dimensionality reduction via PCA; (ix) formal feature selection using filter, wrapper and embedded methods; and (x) statistical validation of the final dataset, including residual multicollinearity removal, yielding 21 features with high inter-class separability. All stages were implemented with strict data-leakage control, fitting parameters exclusively on training data (folds 1–8). The final dataset (`dataset_final_validado.parquet`) is ready for input into PR classifiers.

Keywords: Electrocardiogram. Biosignals. Pattern recognition. Feature extraction. PTB-XL. Machine learning.

LISTA DE FIGURAS

Figura 1 – Distribuição demográfica dos pacientes do PTB-XL: histograma de idades por sexo (esq.) e proporção por sexo (dir.)	39
Figura 2 – Distribuição do SNR por classe de qualidade e por derivação	42
Figura 3 – Matrizes de correlação de Pearson e Spearman entre variáveis demográficas e métricas do sinal de ECG	46
Figura 4 – ZCR e variância por superclasse diagnóstica — análise de estabilidade intra-janela (derivação DII, amostra de 5.000 registros)	50
Figura 5 – PSD média estimada via Welch na derivação DII por superclasse diagnóstica	53
Figura 6 – Top 30 <i>features</i> por <i>F</i> -statistic máxima (ANOVA <i>one-vs-rest</i> , conjunto de treino), coloridas pela superclasse dominante	57
Figura 7 – <i>Heatmap</i> de <i>loadings</i> dos 10 primeiros componentes principais sobre as Top 40 <i>features</i> de maior contribuição	60
Figura 8 – Top-30 features por importância Gini (Random Forest) e curva de importância acumulada com marcação dos limiares de 50, 75, 90 e 99%	63
Figura 9 – <i>Heatmap</i> de correlação residual entre as 21 features após remoção iterativa por VIF (limiar = 10), calculado sobre o conjunto de treino	66

LISTA DE TABELAS

Tabela 1 – Grupos de derivações do ECG de 12 derivações e respectivas regiões monitoradas	30
Tabela 2 – Pesos atribuídos a cada método no Borda Count ponderado	30
Tabela 3 – Superclasses diagnósticas do PTB-XL e respectiva descrição clínica	32
Tabela 4 – Resumo das etapas do pipeline de biossinais	35
Tabela 5 – Principais decisões metodológicas adotadas no pipeline	37
Tabela 6 – Distribuição dos registros por conjunto após a partição treino/validação/teste	40
Tabela 7 – Distribuição das classes SQI por presença de problema anotado nos metadados (%)	42
Tabela 8 – Distribuição das categorias de qualidade SQI antes e depois da aplicação da pipeline de limpeza	48
Tabela 9 – Métricas inter-janela medianas por superclasse diagnóstica	51
Tabela 10 – Resumo das features de segunda ordem construídas no Entregável 7	56
Tabela 11 – Componentes independentes candidatos a descarte (menor F -score combinado com menor curtose)	61
Tabela 12 – Número de features com separação estatisticamente significativa (Mann-Whitney U, $p_{\text{FDR}} < 0,05$) por par de superclasses	67

LISTA DE SÍMBOLOS

$x(t)$	Sinal de ECG contínuo no tempo
$x[n]$	Sinal de ECG discreto (amostrado)
f_s	Frequência de amostragem (Hz)
f_N	Frequência de Nyquist = $f_s/2$
N	Número total de amostras de um registro
L	Número de derivações (canais) do ECG; $L = 12$
A_R	Amplitude do pico R (mV)
T_{QRS}	Duração do complexo QRS (ms)
ΔST	Desvio do segmento ST em relação à linha isoeletrica (mV)
A_T	Amplitude da onda T (mV)
RR_i	Intervalo entre os picos R consecutivos i e $i + 1$ (ms)
$\overline{RR}$	Média dos intervalos RR (ms)
SDNN	Desvio-padrão dos intervalos RR (ms)
RMSSD	Raiz quadrática média das diferenças sucessivas de RR (ms)
CV_{RR}	Coefficiente de variação dos intervalos RR
SD_1	Desvio-padrão de curto prazo no diagrama de Poincaré (ms)
SD_2	Desvio-padrão de longo prazo no diagrama de Poincaré (ms)
$S(f)$	Densidade espectral de potência (PSD) — método de Welch
P_{PT}	Potência na banda P/T (0,5–5 Hz)
P_{QRS}	Potência na banda QRS (5–25 Hz)
ψ	Função wavelet-mãe (Daubechies db4)
A_j	Coefficientes de aproximação no nível j
D_j	Coefficientes de detalhe no nível j
E_{D_j}	Energia relativa dos coeficientes de detalhe D_j
H_{Sh}	Entropia de Shannon dos coeficientes wavelet
α	Expoente de escala do DFA (<i>Detrended Fluctuation Analysis</i>)

FD	Dimensão fractal de Higuchi ($k_{\max} = 10$)
SampEn	Entropia de amostra ($m = 2, r = 0,2\sigma$)
K	Número de componentes principais retidos pelo PCA; $K = 79$
η^2	Eta-quadrado (tamanho de efeito da ANOVA)
F	Estatística F da ANOVA
p	Valor-p do teste estatístico
f_{hp}	Frequência de corte do filtro passa-alta; $f_{hp} = 0,5$ Hz
f_{lp}	Frequência de corte do filtro passa-baixa; $f_{lp} = 40$ Hz
n_B	Ordem dos filtros Butterworth; $n_B = 5$

SUMÁRIO

1	INTRODUÇÃO	12
1.1	Dataset PTB-XL e Motivação da Escolha	13
1.2	Objetivos	14
<i>1.2.1</i>	<i>Objetivo Geral</i>	<i>14</i>
<i>1.2.2</i>	<i>Objetivos Específicos</i>	<i>14</i>
1.3	Organização do Trabalho	15
2	FUNDAMENTAÇÃO TEÓRICA	16
2.1	Eletrocardiograma de 12 Derivações	16
<i>2.1.1</i>	<i>Morfologia do Sinal de ECG</i>	<i>16</i>
<i>2.1.2</i>	<i>Sistema de Derivações</i>	<i>16</i>
2.2	Avaliação da Qualidade de Sinais Biomédicos	17
<i>2.2.1</i>	<i>Métricas no Domínio do Tempo</i>	<i>17</i>
<i>2.2.2</i>	<i>Métricas no Domínio da Frequência</i>	<i>18</i>
<i>2.2.3</i>	<i>Classificador Heurístico em Cascata</i>	<i>18</i>
2.3	Processamento Digital de Sinais de ECG	19
<i>2.3.1</i>	<i>Filtragem Digital Butterworth</i>	<i>19</i>
<i>2.3.2</i>	<i>Winsorização e Controle de Outliers</i>	<i>19</i>
2.4	Segmentação de Sinais de ECG	20
<i>2.4.1</i>	<i>Detector de Pico R: Algoritmo Pan-Tompkins</i>	<i>20</i>
<i>2.4.2</i>	<i>Janelamento em Nível de Batimento</i>	<i>20</i>
2.5	Extração de Atributos de Sinais Biomédicos	21
<i>2.5.1</i>	<i>Domínio do Tempo</i>	<i>21</i>
<i>2.5.2</i>	<i>Domínio da Frequência</i>	<i>21</i>
<i>2.5.3</i>	<i>Análise Morfológica e Variabilidade da Frequência Cardíaca</i>	<i>21</i>
<i>2.5.4</i>	<i>Domínio Tempo-Frequência: Transformada Wavelet Discreta</i>	<i>22</i>
<i>2.5.5</i>	<i>Análise Não-Linear</i>	<i>22</i>
2.6	Engenharia de Features	22
<i>2.6.1</i>	<i>Limpeza Analítica do Vetor de Atributos</i>	<i>23</i>
<i>2.6.2</i>	<i>Features de Segunda Ordem</i>	<i>23</i>
<i>2.6.3</i>	<i>Normalização Robusta por RobustScaler</i>	<i>23</i>

2.6.4	<i>Validação de Relevância e Redundância</i>	24
2.7	Redução de Dimensionalidade	24
2.7.1	<i>Análise de Componentes Principais (PCA)</i>	24
2.7.2	<i>Análise de Componentes Independentes (FastICA)</i>	25
2.8	Seleção de Atributos	25
2.8.1	<i>Métodos Filter</i>	25
2.8.2	<i>Métodos Wrapper</i>	26
2.8.3	<i>Métodos Embedded</i>	26
2.8.4	<i>Ranking por Borda Count Ponderado</i>	26
2.9	Validação Estatística	27
2.9.1	<i>Testes de Normalidade</i>	27
2.9.2	<i>Testes de Homocedasticidade</i>	27
2.9.3	<i>Testes Não Paramétricos para Comparação de Grupos</i>	27
2.9.4	<i>Medidas de Associação</i>	28
2.9.5	<i>Fator de Inflação da Variância (VIF)</i>	28
2.9.6	<i>Análise Discriminante Linear (LDA)</i>	28
2.9.7	<i>Coeficiente de Bhattacharyya</i>	29
3	METODOLOGIA	31
3.1	Dataset PTB-XL	31
3.1.1	<i>Superclasses Diagnósticas</i>	31
3.1.2	<i>Estratificação em Folds e Controle de Data Leakage</i>	32
3.2	Ferramentas e Ambiente Computacional	33
3.3	Visão Geral do Pipeline	34
3.4	Decisões Metodológicas Relevantes	35
4	RESULTADOS	38
4.1	Entregável 1 — Aquisição dos Biossinais	38
4.2	Entregável 2 — Avaliação da Qualidade do Sinal (SQI)	40
4.3	Entregável 3 — Análise Estatística Inicial	43
4.4	Entregável 4 — Limpeza e Filtragem Digital dos Sinais	46
4.5	Entregável 5 — Segmentação (Janelamento)	49
4.6	Entregável 6 — Extração de Atributos	52
4.7	Entregável 7 — Engenharia de Features	54

4.8	Entregável 8 — Redução de Dimensionalidade	59
4.9	Entregável 9 — Seleção de Atributos	62
4.10	Entregável 10 — Validação Estatística Final do Dataset	65
5	CONCLUSÕES E TRABALHOS FUTUROS	71
5.1	Síntese dos Resultados	71
5.2	Contribuições	73
5.3	Limitações	74
5.4	Trabalhos Futuros	75
	REFERÊNCIAS	76

1 INTRODUÇÃO

As doenças cardiovasculares representam a principal causa de mortalidade global, sendo responsáveis por aproximadamente 17,9 milhões de óbitos por ano, o equivalente a 32% de todas as mortes registradas no mundo (KLIGFIELD *et al.*, 2007). No Brasil, o cenário é igualmente preocupante: as doenças do aparelho circulatório lideram as causas de morte há décadas e respondem por parcela expressiva dos internamentos hospitalares do Sistema Único de Saúde. Nesse contexto, o diagnóstico precoce e preciso de condições cardíacas constitui um imperativo clínico e de saúde pública.

O eletrocardiograma de 12 derivações (eletrocardiograma (ECG)) é o exame de triagem cardiovascular de maior custo-benefício disponível na prática clínica. De execução rápida, baixo custo e ampla disponibilidade, o ECG fornece registro da atividade elétrica cardíaca sob doze perspectivas espaciais simultâneas, permitindo detectar arritmias, síndromes coronárias agudas, distúrbios de condução, hipertrofias e diversas outras condições. Sua interpretação, no entanto, é uma tarefa que exige treinamento especializado, é demorada quando realizada de forma sistemática em grandes volumes de exames, e está sujeita à variabilidade interobservador — mesmo entre cardiologistas experientes, há discordâncias diagnósticas em uma fração não desprezível dos casos.

Esses fatores motivam o desenvolvimento de sistemas automatizados de análise de ECG. O problema é formalmente enquadrado como um problema de **Reconhecimento de Padrões** (Reconhecimento de Padrões (RP)): dado um conjunto de registros de ECG com rótulos diagnósticos, o objetivo é construir um modelo capaz de generalizar para novos registros não vistos durante o treinamento. Ao longo das últimas décadas, abordagens baseadas em *Machine Learning* / Aprendizado de Máquina (ML) — incluindo máquinas de vetores de suporte, florestas aleatórias, redes neurais convolucionais e *transformers* — alcançaram desempenho comparável ou superior ao de especialistas humanos em tarefas específicas de diagnóstico por ECG.

Para que esses algoritmos operem com eficácia, contudo, é imprescindível que os dados de entrada sejam rigorosamente preparados. A qualidade do pipeline de pré-processamento determina, em grande medida, o teto de desempenho dos classificadores: modelos sofisticados treinados sobre dados ruidosos ou mal representados raramente superam modelos simples treinados sobre dados bem preparados. Essa premissa é amplamente reconhecida na literatura, mas sistematicamente subestimada na prática — a etapa de preparação de dados raramente recebe atenção proporcional à etapa de modelagem.

Um pipeline completo de preparação de biossinais para RP envolve, no mínimo, as seguintes etapas: (i) **aquisição e inspeção** dos dados brutos, verificando integridade, completude e ausência de vazamento de dados entre conjuntos; (ii) **avaliação objetiva de qualidade** do sinal, identificando registros comprometidos por artefatos de aquisição; (iii) **análise estatística inicial**, que fundamenta as decisões metodológicas sobre quais testes e transformações são adequados para os dados em questão; (iv) **pré-processamento e filtragem**, visando à remoção de ruídos e artefatos sem distorção das características clínicas; (v) **segmentação**, que define as unidades de análise sobre as quais as features serão extraídas; (vi) **extração de atributos**, transformando o sinal contínuo em vetores numéricos de dimensão fixa; (vii) **engenharia de features**, criando representações de segunda ordem e normalizando o espaço de atributos; (viii) **redução de dimensionalidade** ou **seleção de atributos**, comprimindo o espaço sem perda relevante de informação discriminativa; e (ix) **validação estatística** do dataset resultante, antes de sua entrega aos classificadores.

A ausência de qualquer dessas etapas compromete a validade dos modelos obtidos e dificulta a comparação de resultados entre estudos. A falta de padronização no pipeline de preparação é, aliás, uma das principais razões pelas quais resultados publicados na literatura de análise automática de ECG frequentemente não se reproduzem em cenários clínicos reais: as diferenças de desempenho entre estudos frequentemente refletem diferenças metodológicas na preparação dos dados, não diferenças intrínsecas entre os classificadores comparados.

1.1 Dataset PTB-XL e Motivação da Escolha

Este trabalho utiliza o **PTB-XL** (WAGNER *et al.*, 2020), a maior base de dados pública de ECG de 12 derivações disponível atualmente. Com 21.799 registros de 18.869 pacientes, coletados ao longo de mais de uma década no *Physikalisch-Technische Bundesanstalt* (PTB), em Berlim, e anotados por múltiplos cardiologistas segundo o padrão SCP-ECG, o PTB-XL reúne propriedades que o tornam especialmente adequado para o desenvolvimento e a validação de pipelines de RP:

- **Escala:** 21.799 registros representam um volume suficiente para treinar e avaliar classificadores com robustez estatística, em contraste com bases menores (centenas de registros) que dificultam a generalização.
- **Diversidade clínica:** 71 classes diagnósticas organizadas em cinco superclasses — ritmo normal, infarto do miocárdio, alterações de ST/T, distúrbios de condução e hipertrofias

—, com suporte a múltiplos rótulos por registro, refletindo a realidade de pacientes com condições sobrepostas.

- **Partição estratificada:** o dataset fornece nativamente uma divisão em dez folds estratificados por paciente, garantindo que todos os registros de um mesmo indivíduo pertençam ao mesmo fold e que os conjuntos de treino, validação e teste sejam disjuntos em nível de paciente.
- **Reprodutibilidade:** disponibilizado publicamente no PhysioNet sob licença Creative Commons, com formato padronizado WFDB e metadados completos, o PTB-XL permite a reprodução integral dos resultados por outros grupos de pesquisa.
- **Relevância clínica:** os registros foram coletados em ambiente hospitalar real, com a diversidade de condições de aquisição — variações de impedância, diferentes equipamentos, múltiplos operadores — que caracteriza dados clínicos reais.

1.2 Objetivos

1.2.1 *Objetivo Geral*

Preparar um dataset de biossinais de ECG para aplicação de técnicas de RP, percorrendo todo o pipeline de aquisição, pré-processamento, extração de atributos e validação estatística, utilizando o dataset PTB-XL.

1.2.2 *Objetivos Específicos*

1. Realizar a aquisição e inspeção dos sinais brutos do dataset PTB-XL (21.799 registros, 12 derivações, 100 Hz), verificando integridade dos metadados e ausência de vazamento entre folds;
2. Quantificar objetivamente a qualidade dos sinais por métricas SQI e classificá-los em categorias de qualidade (G/A/P/U) por meio de um classificador heurístico em cascata;
3. Conduzir a análise estatística inicial dos metadados e das métricas do sinal por superclasse diagnóstica, verificando normalidade e homocedasticidade para fundamentar as decisões metodológicas;
4. Implementar o pipeline de pré-processamento com filtragem digital Butterworth bidirecional (passa-alta 0,5 Hz e passa-baixa 40 Hz) e winsorização de outliers,

- com rigoroso controle de *data leakage*;
5. Segmentar os sinais em dois níveis: registro de 10 s como instância principal e batimento individual de 600 ms via detector Pan-Tompkins como unidade auxiliar para extração de features morfológicas;
 6. Extrair atributos distribuídos em cinco domínios: tempo, frequência, morfologia/HRV, tempo-frequência (DWT) e não-linear;
 7. Aplicar engenharia de features com criação de atributos de segunda ordem (razões espectrais, normalizações por *baseline* NORM e deltas morfológicos) e normalização robusta por RobustScaler;
 8. Reduzir a dimensionalidade por PCA com variância acumulada $\geq 95\%$ ($K = 79$ componentes) e analisar a estrutura latente via FastICA;
 9. Selecionar formalmente o subconjunto de atributos de maior poder discriminativo por métodos *filter*, *wrapper* e *embedded*, consolidados via Borda Count ponderado, resultando em 30 features interpretáveis;
 10. Validar estatisticamente o dataset final com remoção de multicolinearidade residual por VIF iterativo e análise de separabilidade, entregando 21 atributos prontos para o módulo de RP.

1.3 Organização do Trabalho

Este trabalho está organizado da seguinte forma. O Capítulo 2 apresenta a fundamentação teórica sobre o ECG de 12 derivações, avaliação de qualidade de sinais biomédicos, processamento digital, segmentação, extração de atributos nos cinco domínios adotados, engenharia de features, redução de dimensionalidade, seleção de atributos e validação estatística. O Capítulo 3 descreve o dataset PTB-XL, o ambiente computacional e a visão geral do pipeline, incluindo as principais decisões metodológicas e suas justificativas. O Capítulo 4 apresenta os resultados de cada uma das dez etapas do pipeline, do Entregável 1 ao Entregável 10, com tabelas, figuras e interpretação dos achados. Por fim, o Capítulo 5 sintetiza as contribuições do trabalho, discute as limitações identificadas e aponta direções para pesquisas futuras.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 Eletrocardiograma de 12 Derivações

O eletrocardiograma (ECG) é o registro gráfico da atividade elétrica do coração ao longo do tempo, obtido por eletrodos posicionados na superfície corporal. Cada ciclo cardíaco produz uma sequência ordenada de potenciais de ação — despolarização atrial, seguida de despolarização e repolarização ventricular — captada sob diferentes perspectivas espaciais, dando origem às derivações. Do ponto de vista clínico, o ECG de 12 derivações é o exame de triagem cardiovascular de maior custo-benefício disponível, utilizado no diagnóstico de arritmias, síndromes coronárias agudas, distúrbios de condução e hipertrofias (KLIGFIELD *et al.*, 2007).

2.1.1 Morfologia do Sinal de ECG

Em condições normais, cada batimento é representado por três componentes: a **onda P** (despolarização atrial; duração < 120 ms, amplitude $< 0,25$ mV em DII); o **complexo QRS** (despolarização ventricular; duração normal de 80–120 ms; valores > 120 ms indicam distúrbio de condução); e a **onda T** (repolarização ventricular). O **segmento ST** — compreendido entre o ponto J e o início da onda T — é de particular relevância clínica: sua elevação ou depressão são marcadores primários de isquemia miocárdica.

2.1.2 Sistema de Derivações

O ECG de 12 derivações é constituído por três grupos funcionais, apresentados na Tabela 1.

As derivações dos membros bipolares (I, II, III) compõem o triângulo de Einthoven. As derivações unipolares aumentadas (aVR, aVL, aVF) registram o potencial de cada membro em relação à média dos outros dois. As seis derivações precordiais (V1–V6), posicionadas de forma padronizada pelo comitê AHA/ACC/HRS (KLIGFIELD *et al.*, 2007), capturam a progressão do vetor elétrico no plano horizontal.

Protocolo de Aquisição do PTB-XL

O dataset PTB-XL foi coletado entre 1984 e 2001 no PTB, em Berlim, com equipamentos Schiller AG em 51 pontos de coleta (WAGNER *et al.*, 2020). Os sinais foram

digitalizados a 400 Hz e reamostrados para 500 Hz; uma versão decimada a 100 Hz — adotada neste trabalho — acompanha o dataset. A resolução é de 16 bits ($1 \mu\text{V/LSB}$), e os arquivos são armazenados no formato WFDB. O processo de rotulagem seguiu múltiplas etapas: laudo por cardiologista ou gerado automaticamente, conversão para códigos SCP-ECG e revisão por segundo especialista; 73,7% dos registros possuem validação humana confirmada.

Justificativa da Taxa de 100 Hz

O Teorema de Nyquist-Shannon estabelece que a taxa de amostragem f_s deve satisfazer:

$$f_s \geq 2 \cdot f_{\max} \quad (2.1)$$

A banda de interesse clínico do ECG diagnóstico é 0,05–40 Hz (KLIGFIELD *et al.*, 2007), exigindo $f_{s,\min} = 80$ Hz. A taxa de 100 Hz supera esse limiar com margem de 25%, garantindo reconstrução fiel sem *aliasing* e reduzindo o custo computacional em $5\times$ frente à taxa de 500 Hz — fator relevante no processamento em lote de 21.799 registros. A frequência de Nyquist resultante (50 Hz) inviabiliza a aplicação de filtro notch para a rede elétrica.

2.2 Avaliação da Qualidade de Sinais Biomédicos

Sinais de ECG coletados em ambiente clínico real estão sujeitos a diversas fontes de degradação: **deriva de linha de base** (oscilações $< 0,5$ Hz, distorce o segmento ST); **ruído muscular** (EMG, espectro de alta frequência); **ruído estático** (gaussiano, banda larga); **ruído impulsivo** (transitórios de grande amplitude por falhas de eletrodo); e **interferência da rede elétrica** (50/60 Hz, indetectável a 100 Hz). A identificação objetiva dessas degradações é pré-requisito para decisões reproduzíveis sobre quais registros analisar, pré-processar ou descartar.

2.2.1 Métricas no Domínio do Tempo

hosSQI: índice baseado em curtose ($kSQI$) e assimetria ($sSQI$) da distribuição de amplitudes, calculado como:

$$hosSQI = \frac{|sSQI| \times kSQI}{5} \quad (2.2)$$

Valores elevados correspondem a sinais com morfologia consistente.

Flat ratio e flatline: o *flat ratio* mede a proporção de amostras com variação absoluta inferior a um limiar ε , sinalizando saturação ou perda de contato. A presença de segmento constante $\geq 1,5$ s (*flatline flag*) indica falha grave de aquisição.

qSQI: avalia a regularidade dos intervalos RR estimados por detector de pico simplificado:

$$qSQI = 1 - \frac{\sigma_{RR}}{\bar{RR}} \quad (2.3)$$

Valores próximos a 1 indicam ritmo regular; valores baixos revelam instabilidade morfológica.

2.2.2 Métricas no Domínio da Frequência

pSQI: concentração de energia na banda do QRS (5–15 Hz) em relação à energia total (5–40 Hz), via estimação de PSD pelo método de Welch. Ruído muscular dilui essa concentração, reduzindo o pSQI.

basSQI: razão entre a energia acima de 1 Hz e a energia total (0–40 Hz); sinais com *baseline drift* severo apresentam basSQI elevado.

SNR estimado: razão entre a potência RMS do sinal filtrado (passa-banda 0,5–40 Hz, Butterworth ordem 4) e a potência RMS do ruído residual, expressa em dB. Valores negativos indicam que o ruído domina.

Entropia espectral: distribuição de energia ao longo das frequências, pela entropia de Shannon da PSD normalizada:

$$H = - \sum_k \hat{P}(f_k) \log_2 \hat{P}(f_k) \quad (2.4)$$

O resultado é normalizado pelo máximo teórico ($\log_2 N$): ECG limpo apresenta entropia baixa; ruído branco, próxima a 1.

rinter: média das correlações de Pearson entre todos os pares de derivações válidas. Valores elevados indicam coerência multicanal esperada em um ECG bem adquirido.

2.2.3 Classificador Heurístico em Cascata

As métricas são combinadas em um classificador heurístico em cascata (*Gatekeeper*) que atribui uma de quatro categorias: **G — Excelente**; **A — Aceitável**; **P — Processável** (degradações tratáveis por filtragem); **U — Inaceitável** (falha estrutural, descartado). A lógica opera em dois estágios: no *hard gate*, critérios de exclusão imediata ($\text{flat_ratio} > 0,25$, $\text{SNR} <$

0 dB, flatline $\geq 1,5$ s ou $qSQI < 0,6$) classificam diretamente como U; registros restantes são avaliados por múltiplos limiares sobre hosSQI, pSQI, basSQI, entropia espectral e rinter. Os limiares são ajustados empiricamente com variação de $\pm 10\%$ em relação a valores da literatura.

2.3 Processamento Digital de Sinais de ECG

O pré-processamento visa reduzir artefatos sem distorcer características fisiológicas essenciais. Dois grupos de interferência são tratados de forma independente: componentes de baixa frequência (variações respiratórias, movimentos, instabilidade de eletrodos) e de alta frequência (EMG, interferências elétricas).

2.3.1 Filtragem Digital Butterworth

O filtro de Butterworth caracteriza-se por resposta maximamente plana na banda passante e decaimento monotônico na banda de rejeição (OPPENHEIM; SCHAFER, 1999):

$$|H(j\omega)|^2 = \frac{1}{1 + \left(\frac{\omega}{\omega_c}\right)^{2n}} \quad (2.5)$$

Dois filtros de ordem 5 em cascata definem implicitamente um passa-faixa de 0,5–40 Hz: o **passa-alta** ($f_c = 0,5$ Hz) remove o *drift* de linha de base, e o **passa-baixa** ($f_c = 40$ Hz) atenua ruído muscular e interferências elétricas, limites adotados pela norma AHA/ACC (KLIGFIELD *et al.*, 2007). A implementação utiliza filtragem bidirecional (`filtfilt`), que cancela a distorção de fase introduzida por filtros causais, preservando o alinhamento temporal das ondas P, QRS e T (GUSTAFSSON, 1996). A interferência de rede elétrica (50 Hz) não é tratada com filtro notch, pois coincide com a frequência de Nyquist da série decimada.

2.3.2 Winsorização e Controle de Outliers

A winsorização limita os dados a um intervalo definido pelos percentis 0,5% e 99,5% da distribuição empírica de cada derivação, calculados sobre amostra dos folds de treino (TUKEY, 1977). O cálculo por derivação é necessário porque as distribuições de amplitude diferem sistematicamente entre canais. A restrição ao conjunto de treino evita *data leakage*: os limites calculados são aplicados, sem reajuste, a todos os registros do pipeline.

2.4 Segmentação de Sinais de ECG

A segmentação transforma o sinal contínuo em instâncias discretas. Três abordagens são predominantes: **janela deslizante com sobreposição** (amplamente adotada em *Deep Learning*, mas introduz correlação artificial entre amostras em *pipelines* clássicos); **janela sem sobreposição** (instâncias independentes, preferível para *features* manuais); e **segmentação por eventos fisiológicos** (alinhada ao pico R, ideal para *features* morfológicas e de HRV, dependendo da qualidade do detector). Neste trabalho, adota-se a segmentação por pico R.

2.4.1 Detector de Pico R: Algoritmo Pan-Tompkins

O algoritmo Pan-Tompkins (PAN; TOMPKINS, 1985) é o método de referência para detecção de ondas R, operando em cinco etapas sobre a derivação DII. (1) **Filtragem passa-banda** (5–15 Hz), isolando a faixa do QRS. (2) **Derivação e quadratura**, obtendo a energia instantânea $s[n] = (y[n] - y[n-1])^2$, que acentua inclinações rápidas e suprime flutuações lentas. (3) **Integração por janela móvel** de ≈ 150 ms:

$$I[n] = \frac{1}{N_w} \sum_{k=0}^{N_w-1} s[n-k] \quad (2.6)$$

produzindo uma envoltória de energia. (4) **Detecção de picos** acima de limiar de proeminência (percentil 95% de $I[n]$) com período refratário inicial de 200 ms. (5) **Período refratário adaptativo** recalibrado para 60% do intervalo RR mediano detectado, acomodando taquicardias sem aumentar detecções duplas.

2.4.2 Janelamento em Nível de Batimento

Cada batimento é delimitado por uma janela de **600 ms** centrada assimetricamente: 200 ms anteriores ao pico R e 400 ms posteriores (60 amostras a 100 Hz). A assimetria é fisiologicamente motivada: os 400 ms pós-pico acomodam o segmento ST e a onda T, e os 200 ms pré-pico cobrem a onda P e o intervalo PR. Batimentos com índice de pico R inferior a 20 amostras ou superior a $N - 40$ são descartados. O produto é um tensor ($N_{\text{batimentos}} \times 60 \times 12$); *features* morfológicas são agregadas por mediana e desvio padrão ao nível do registro, preservando a independência amostral.

2.5 Extração de Atributos de Sinais Biomédicos

A extração de atributos transforma sinais contínuos em vetores numéricos utilizáveis por algoritmos de aprendizado. A estratégia adotada é hierárquica e híbrida: atributos globais são extraídos sobre o registro completo de 10 s nas 12 derivações; atributos morfológicos e de HRV são extraídos por batimento e agregados ao nível do registro.

2.5.1 Domínio do Tempo

Sete atributos por derivação são calculados diretamente sobre o vetor de amplitudes: **RMS** ($\sqrt{\frac{1}{N} \sum x[n]^2}$, energia quadrática média); **MAV** ($\frac{1}{N} \sum |x[n]|$, menos sensível a picos extremos); **variância** (σ^2 , dispersão de amplitudes); **pico a pico** (P2P, sensível a deflexões dominantes e elevado em hipertrofia); **taxa de cruzamento por zero** (ZCR, correlaciona-se com conteúdo de alta frequência); e os momentos de terceira e quarta ordem — **skewness** (assimetria) e **kurtosis** (achatamento), que em ECG limpo refletem os picos abruptos do QRS.

2.5.2 Domínio da Frequência

A PSD é estimada pelo **método de Welch** (OPPENHEIM; SCHAFER, 1999) (segmento de 256 amostras, sobreposição de 50%, janela de Hann), reduzindo a variância da estimativa para sinais não-estacionários. A partir da PSD, extraem-se sete atributos por derivação: **potência na banda PT** (0,5–5 Hz); **potência na banda QRS** (5–25 Hz); **potência total** (0,5–40 Hz); **razão QRS/Total** (adimensional, robusta a variações de escala); **frequência de pico**; **frequência mediana** (divide a potência total em duas metades iguais); e **centroide espectral** $\bar{f} = \sum_k f_k \cdot S(f_k) / \sum_k S(f_k)$.

2.5.3 Análise Morfológica e Variabilidade da Frequência Cardíaca

Operando sobre janelas de 600 ms centradas no pico R, extraem-se: **amplitude R** (reduzida em infarto, elevada em hipertrofia); **duração do QRS** (valores > 120 ms caracterizam bloqueios de ramo); **amplitude do segmento ST** (elevação > 1 mV indica lesão aguda; depressão aponta isquemia subendocárdica); e **amplitude da onda T**. Para HRV, a série de intervalos RR fornece quatro métricas temporais (Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology, 1996): **meanRR** (inverso da FC média), **SDNN** (variabilidade global), **RMSSD** (variabilidade de curto prazo, associada ao tônus

vagal) e **CV_RR** (variabilidade normalizada pela FC média).

2.5.4 Domínio Tempo-Frequência: Transformada Wavelet Discreta

A DWT decompõe o sinal em sub-bandas por banco de filtros em cascata, preservando informação temporal e espectral (MALLAT, 1999). Em quatro níveis sobre sinal a 100 Hz, as sub-bandas cobrem: A_4 (0–6,25 Hz, ondas P e T); D_4 (6,25–12,5 Hz); D_3 (12,5–25 Hz, pico do QRS); D_2 e D_1 (ruído residual). Adota-se a família **Daubechies db4**, cuja assimetria e suavidade refletem melhor as morfologias cardíacas. Extraem-se por sub-banda: **energia** $E_k = \sum_n c_k[n]^2$; **energia relativa** $E_k / \sum_j E_j$; e **entropia de Shannon** dos coeficientes. Uma **razão QRS wavelet** $(E_{D_3} + E_{D_4}) / E_{\text{total}}$ oferece descritor espectral relativo com melhor localização temporal que a FFT.

2.5.5 Análise Não-Linear

Quatro atributos capturam a complexidade dinâmica do ritmo cardíaco. A **dimensão fractal de Higuchi** (D_H) (HIGUCHI, 1988) estima a complexidade geométrica da série temporal: em ECG saudável $D_H \approx 1,5$; perda de complexidade patológica reduz D_H em direção a 1,0. A **DFA** quantifica auto-correlações de longo alcance estimando o expoente α : $\alpha \approx 1,0$ indica dinâmica fractal saudável; $\alpha > 1,5$ indica correlações suaves; $\alpha < 0,5$ sugere arritmias graves. A **entropia de amostra** (SampEn) (RICHTMAN; MOORMAN, 2000) mede a imprevisibilidade da série RR ($m = 2$, $r = 0,2\sigma$): valores elevados indicam ritmo caótico (FA), valores baixos indicam ritmo rígido (bloqueios). O **diagrama de Poincaré** (Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology, 1996) representa RR_{n+1} em função de RR_n ; os eixos da elipse ajustada definem **SD1** (variabilidade de curto prazo, parassimpática; $= \text{RMSSD} / \sqrt{2}$) e **SD2** (variabilidade de longo prazo; integra componentes simpáticas e parassimpáticas), com SD1/SD2 como índice do equilíbrio autonômico.

2.6 Engenharia de Features

A engenharia de *features* transforma a representação numérica bruta em uma forma mais adequada para algoritmos de aprendizado, abrangendo: limpeza do vetor de atributos, construção de *features* derivadas, normalização robusta e validação de relevância e redundância.

2.6.1 Limpeza Analítica do Vetor de Atributos

Features quasi-constantes (variância $< 10^{-6}$) não discriminam classes e causam instabilidade numérica em algoritmos baseados em escala ou IQR, sendo removidas preventivamente. **Features com alta taxa de valores ausentes** ($> 5\%$) são descartadas, pois medianas calculadas sobre menos de 95% das amostras tornam-se progressivamente enviesadas (BISHOP, 2006). Atributos com menos de 5% de NaN são preservados e imputados pela **mediana estratificada por superclasse**, calculada exclusivamente sobre o conjunto de treino — respeitando diferenças fisiológicas entre classes e evitando *data leakage*.

2.6.2 Features de Segunda Ordem

Três tipos de *features* derivadas possuem interpretação fisiológica direta. **Razões entre bandas espectrais** são adimensionais e invariantes à amplitude absoluta: dois registros com morfologia idêntica mas amplitudes distintas produzem razões iguais, tornando-as robustas para comparação interindividual. **Normalização por baseline NORM** expressa cada atributo como múltiplo da mediana do grupo normal (treino), de modo que 1,0 corresponde ao padrão fisiológico e desvios quantificam o afastamento clínico. **Deltas morfológicos inter-derivações** capturam gradientes elétricos entre pares anatomicamente complementares (DI–aVR, V1–V6, V2–V5), revelando inversão de eixo, bloqueios de ramo e padrões de infarto que *features* individuais não representam.

2.6.3 Normalização Robusta por RobustScaler

O vetor de atributos reúne grandezas de domínios e ordens de grandeza distintos. O RobustScaler (PEDREGOSA *et al.*, 2011) centraliza pela mediana Q_{50} e divide pelo IQR:

$$z_i = \frac{x_i - Q_{50}}{Q_{75} - Q_{25}} \quad (2.7)$$

É preferível ao StandardScaler em distribuições com caudas pesadas, pois o IQR é determinado pelos 50% centrais e imune a valores extremos — condição documentada para praticamente todas as *features* de ECG. O escalonador é **fitado exclusivamente nos folds de treino** e apenas aplicado (*transform*) a validação e teste, evitando *data leakage*.

2.6.4 Validação de Relevância e Redundância

Duas análises orientam a seleção formal posterior. A **ANOVA F -statistic one-vs-rest** avalia o poder discriminativo individual de cada *feature* para cada superclasse diagnóstica, via `f_classif` do scikit-learn (PEDREGOSA *et al.*, 2011), sem depender de nenhum modelo específico. A **correlação de Pearson entre pares** identifica atributos redundantes ($|r| > 0,90$) — candidatos à remoção por não adicionar informação independente — conduzida sobre as 50 *features* de maior F -statistic.

2.7 Redução de Dimensionalidade

A redução de dimensionalidade é motivada pela **maldição da dimensionalidade**: em espaços de alta dimensão, as distâncias perdem discriminabilidade, o custo computacional cresce problematicamente e o risco de *overfitting* aumenta quando o número de *features* supera $\sqrt{N}$ (BISHOP, 2006). A correlação estrutural elevada entre as *features* produzidas pelo pipeline torna a compressão linear altamente eficiente.

2.7.1 Análise de Componentes Principais (PCA)

O PCA projeta os dados em eixos ordenados por variância decrescente, resolvendo o problema de autovalores da matriz de covariância amostral $\hat{\Sigma}$ (BISHOP, 2006):

$$\hat{\Sigma} \mathbf{v}_i = \lambda_i \mathbf{v}_i \quad (2.8)$$

A variância explicada por cada componente é $VE_i = \lambda_i / \sum_j \lambda_j$. O número de componentes K é definido pelo critério de **variância acumulada** $\geq 95\%$ (limiar adotado), complementado pela análise visual do *Scree Plot* e pelo critério de Kaiser (autovalor > 1). A qualidade da compressão é verificada pelo erro de reconstrução:

$$RMSE = \sqrt{\frac{1}{N \cdot p} \sum_{n,j} (x_{nj} - \hat{x}_{nj})^2} \quad (2.9)$$

A implementação usa SVD da matriz centrada $\mathbf{X}$, mais estável numericamente do que a diagonalização explícita de $\hat{\Sigma}$. Um `StandardScaler` (fitado no treino) é aplicado previamente, pois o PCA é sensível à escala das *features*.

2.7.2 Análise de Componentes Independentes (FastICA)

Enquanto o PCA encontra componentes descorrelacionados, o ICA busca componentes **estatisticamente independentes** — condição mais restritiva que envolve ausência de qualquer forma de dependência (HYVÄRINEN; OJA, 2000). O algoritmo **FastICA** maximiza a neguentropia de cada componente:

$$J(y) = H(y_{\text{gauss}}) - H(y) \quad (2.10)$$

Na prática, o FastICA é aplicado sobre os primeiros componentes PCA, garantindo estabilidade numérica. A relevância de cada componente independente é avaliada pela **ANOVA F-score** (poder discriminativo) e pela **curtose** (grau de não-gaussianidade); componentes com baixo *F*-score e baixa curtose são candidatos a descarte.

2.8 Seleção de Atributos

A seleção de atributos identifica o subconjunto de variáveis que maximiza o poder discriminativo preservando a identidade semântica de cada atributo — diferentemente da redução de dimensionalidade, que projeta os dados em espaço transformado (GUYON; ELISSEEFF, 2003). Os benefícios práticos são: redução do risco de *overfitting*, diminuição do custo computacional e manutenção da interpretabilidade clínica. As três famílias de métodos são aplicadas de forma complementar e consolidadas por agregação de rankings.

2.8.1 Métodos Filter

Avaliam features individualmente por critérios estatísticos independentes do classificador, com custo linear em relação ao número de features.

ANOVA F-score: mensura a separabilidade linear como razão entre variância inter-grupos e intra-grupos:

$$F = \frac{\text{MS}_{\text{between}}}{\text{MS}_{\text{within}}} = \frac{\sum_c n_c (\bar{x}_c - \bar{x})^2 / (C - 1)}{\sum_c \sum_i (x_{ic} - \bar{x}_c)^2 / (N - C)} \quad (2.11)$$

Informação Mútua: quantifica a redução de incerteza sobre a classe ao se conhecer a *feature*: $I(X; Y) = H(Y) - H(Y|X)$. Detecta relações não-lineares, ao contrário do ANOVA F-score (GUYON; ELISSEEFF, 2003). Estimada pelo método de Kraskov baseado em *k* vizinhos mais próximos (KRASKOV *et al.*, 2004).

ReliefF (KONONENKO, 1994): avalia relevância relacional entre instâncias, atualizando a pontuação de cada *feature* com base nos k vizinhos mais próximos dentro da mesma classe (*nearest hits*) e de classes diferentes (*nearest misses*). Captura interações entre *features* implicitamente, pela geometria do espaço multidimensional.

2.8.2 Métodos Wrapper

Avaliam subconjuntos treinando efetivamente um estimador em validação cruzada, capturando interações entre *features*. O estimador utilizado é regressão logística com regularização L2 ($C = 1,0$), em 5-fold CV estratificada, sobre o *top-50* candidatas dos filtros.

O **SFS** (WHITNEY, 1971) parte de conjunto vazio e adiciona iterativamente a *feature* de maior ganho em validação. O **SBE** parte do conjunto completo e remove iterativamente a menos indispensável. A **interseção** entre os subconjuntos SFS e SBE constitui o núcleo de *features* wrapper, robustas por terem sido selecionadas por perspectivas opostas de busca.

2.8.3 Métodos Embedded

O **LASSO** (TIBSHIRANI, 1996) introduz penalidade L1 no critério de otimização:

$$\hat{\beta} = \arg \min_{\beta} \left[\mathcal{L}(\beta) + \lambda \sum_j |\beta_j| \right] \quad (2.12)$$

A penalidade L1 produz soluções esparsas: coeficientes de *features* menos relevantes são levados exatamente a zero. O valor ótimo de $C = 1/\lambda$ é determinado por `LogisticRegressionCV` com 5-fold CV.

O **Random Forest** (BREIMAN, 2001) calcula a importância como redução média ponderada de impureza de Gini:

$$\text{Imp}(f) = \frac{1}{|\mathcal{T}|} \sum_{t \in \mathcal{T}} \sum_{v: \text{split}(v)=f} p(v) \cdot \Delta G(v) \quad (2.13)$$

Captura efeitos principais e interações implícitas; o ensemble produz ranking estável com variância reduzida.

2.8.4 Ranking por Borda Count Ponderado

O Borda Count (YOUNG, 1988) agrega os rankings dos métodos filter, wrapper e embedded sem exigir comparabilidade de escalas — os scores heterogêneos (ANOVA, MI,

ReliefF, RF) são substituídos por ranks antes da soma. Adota-se versão **ponderada**, com pesos por método conforme a Tabela 2.

O score final é a soma dos produtos (rank normalizado $\times$ peso), e o subconjunto final é definido pelo corte nas K features de maior score, combinado com o critério de significância estatística (FDR-BH $< 0,05$).

2.9 Validação Estatística

A validação estatística percorre dois níveis: verificação de pressupostos (normalidade e homocedasticidade) e inferência sobre diferenças entre grupos e associações entre variáveis, com os métodos condicionados pelos resultados do primeiro nível.

2.9.1 Testes de Normalidade

O **teste de Shapiro-Wilk** (SHAPIRO; WILK, 1965) avalia o alinhamento com os quantis esperados de uma distribuição normal, sendo o de maior poder estatístico para amostras até 5.000 observações (RAZALI; WAH, 2011). O **teste de Kolmogorov-Smirnov** compara a CDF empírica com a normal padronizada e é aplicado como verificação independente em datasets de grande escala (MASSEY, 1951). Em ambos, $p < \alpha = 0,05$ implica rejeição da normalidade — mas em amostras grandes até pequenos desvios produzem p -valores baixos; a interpretação deve considerar conjuntamente a estatística e análise visual por **Q-Q plots**.

2.9.2 Testes de Homocedasticidade

O **teste de Levene** (LEVENE, 1960) avalia $H_0 : \sigma_1^2 = \dots = \sigma_k^2$ via ANOVA sobre os desvios absolutos em relação à mediana de cada grupo, conferindo robustez a desvios de normalidade (BROWN; FORSYTHE, 1974). O **teste de Bartlett** (BARTLETT, 1937) é assintoticamente mais poderoso quando a normalidade é satisfeita, mas sensível a desvios desta, sendo mantido apenas como referência complementar.

2.9.3 Testes Não Paramétricos para Comparação de Grupos

Quando normalidade ou homocedasticidade são violadas, recorre-se a métodos baseados em *ranks*, robustos a distribuições assimétricas e *outliers*. O **teste de Kruskal-Wallis** (KRUSKAL; WALLIS, 1952) é a alternativa não paramétrica à ANOVA para k grupos; a

rejeição de H_0 indica que pelo menos um grupo difere, demandando testes *post hoc*. O **teste de Mann-Whitney U** (MANN; WHITNEY, 1947) compara dois grupos independentes e constitui o *post hoc* padrão, frequentemente com correção de Bonferroni ou FDR-BH (BENJAMINI; HOCHBERG, 1995). O **teste de Wilcoxon pareado** (WILCOXON, 1945) aplica-se a amostras dependentes (e.g., mesmo sinal antes e depois de transformação).

2.9.4 Medidas de Associação

A **correlação de Pearson** (r) quantifica relações lineares entre variáveis contínuas, sendo mantida como referência comparativa. A **correlação de Spearman** (ρ) opera sobre *ranks*, sendo robusta a não normalidade e *outliers*, e detecta relações monotônicas não-lineares — adotada como método principal neste trabalho.

2.9.5 Fator de Inflação da Variância (VIF)

A multicolinearidade eleva a variância dos coeficientes em modelos lineares e dilui a importância Gini no Random Forest (MONTGOMERY *et al.*, 2012). O VIF quantifica o grau de colinearidade de cada variável:

$$\text{VIF}_j = \frac{1}{1 - R_j^2} \quad (2.14)$$

onde R_j^2 é o coeficiente de determinação da regressão de j sobre as demais features. $\text{VIF}_j = 1$ indica independência; > 5 é moderado; > 10 indica colinearidade severa. Adota-se **remoção iterativa**: calcula-se o VIF de todas as features, remove-se a de maior VIF quando acima de 10 e repete-se até nenhuma feature ultrapassar o limiar — estratégia preferível à remoção simultânea porque a retirada de uma feature frequentemente reduz o VIF das demais.

2.9.6 Análise Discriminante Linear (LDA)

A LDA (FISHER, 1936) encontra os vetores de projeção $\mathbf{w}$ que maximizam o critério de Fisher:

$$J(\mathbf{w}) = \frac{\mathbf{w}^\top \mathbf{S}_B \mathbf{w}}{\mathbf{w}^\top \mathbf{S}_W \mathbf{w}} \quad (2.15)$$

onde $\mathbf{S}_B$ e $\mathbf{S}_W$ são as matrizes de dispersão entre grupos e dentro dos grupos, respectivamente. Neste trabalho, a LDA é utilizada exclusivamente como ferramenta de visualização: a projeção nos dois primeiros eixos discriminantes permite inspecionar visualmente a separabilidade das classes no plano.

2.9.7 Coeficiente de Bhattacharyya

O coeficiente de Bhattacharyya (BHATTACHARYYA, 1943) quantifica a sobreposição entre duas distribuições:

$$BC(p, q) = \int \sqrt{p(x)q(x)} dx \quad (2.16)$$

$BC = 0$ indica suporte disjunto (separação perfeita); $BC = 1$ indica distribuições idênticas. A **distância de Bhattacharyya** $D_B = -\ln BC$ satisfaz propriedades de semi-métrica. O coeficiente complementa o *effect size* (η^2) por operar diretamente sobre as distribuições estimadas via KDE, sem pressupor forma funcional e capturando sobreposição em qualquer região do suporte.

Tabela 1 – Grupos de derivações do ECG de 12 derivações e respectivas regiões monitoradas

Grupo	Derivações	Região monitorada
Membros bipolares	I, II, III	Plano frontal — diferença de potencial entre pares de eletrodos nos membros
Membros unipolares aum.	aVR, aVL, aVF	Plano frontal — potencial em relação ao terminal central de Wilson modificado
Precordiais	V1, V2, V3, V4, V5, V6	Plano horizontal — progressão do vetor de ativação do septo à parede lateral

Fonte: adaptado de Kligfield *et al.* (2007).

Tabela 2 – Pesos atribuídos a cada método no Borda Count ponderado

Método	Peso	Justificativa
LASSO (L1)	2,0	Seleção multivariada embutida no modelo
Random Forest (Gini)	2,0	Captura interações não-lineares
Informação Mútua	1,5	Dependências não-lineares univariadas
ReliefF	1,5	Relevância relacional por vizinhança
ANOVA F-score	1,0	Separabilidade linear univariada
Wrapper (SFS/SBE)	2,0	Avaliação direta de subconjunto em CV
Effect size (η^2)	1,5	Relevância prática (magnitude do efeito)

Fonte: elaborado pelos autores.

3 METODOLOGIA

3.1 Dataset PTB-XL

O dataset utilizado neste trabalho é o **PTB-XL** (WAGNER *et al.*, 2020), uma base de dados pública de eletrocardiografia disponibilizada no PhysioNet. O PTB-XL contém 21.799 registros de ECG de 12 derivações com duração de 10 s cada, coletados de 18.869 pacientes distintos no período de novembro de 1984 a junho de 2001 no *Physikalisch-Technische Bundesanstalt* (PTB), Berlim, Alemanha, com equipamentos Schiller AG.

Os sinais foram originalmente digitalizados a 400 Hz, reamostrados para 500 Hz e disponibilizados também a 100 Hz via decimação com filtro anti-aliasing. A precisão de conversão é de 16 bits com resolução de $1 \mu\text{V/LSB}$, e os arquivos seguem o formato WFDB (pares .dat/.hea). Os metadados incluem, por registro: data de aquisição, identificador do paciente, idade, sexo, peso, altura, modelo do dispositivo e local de coleta, além de laudos automáticos (gerados pelo software do equipamento) e laudos de ao menos um cardiologista, com indicação de validação por segundo especialista. No total, 73,7% dos registros possuem validação humana confirmada.

O conjunto de anotações clínicas é baseado no padrão SCP-ECG (*Standard Communications Protocol for Computer-Assisted Electrocardiography*), que cobre 71 classes diagnósticas distribuídas em três categorias: ritmo, forma e diagnóstico. O critério adotado para diagnóstico positivo em cada classe é a presença do código SCP-ECG correspondente com *likelihood* (verossimilhança de confirmação diagnóstica) maior ou igual a 50%, conforme convenção do PTB-XL (WAGNER *et al.*, 2020). Para fins deste trabalho, essas 71 classes foram mapeadas em cinco superclasses mutuamente inclusivas, com suporte a multi-label.

3.1.1 Superclasses Diagnósticas

As 71 classes do dicionário SCP-ECG foram agrupadas em cinco superclasses segundo a taxonomia original de Wagner *et al.* (2020), conforme a Tabela 3.

A atribuição de superclasses é multi-label: um mesmo registro pode receber múltiplos rótulos quando apresenta achados pertencentes a mais de uma categoria. Essa característica, somada ao desbalanceamento natural entre as classes — NORM e MI são as mais frequentes, enquanto HYP é a menos representada em valores absolutos —, terá implicações diretas nas estratégias de treinamento dos classificadores de RP, como ponderação de classes (*class_weight*)

Tabela 3 – Superclasses diagnósticas do PTB-XL e respectiva descrição clínica

Sigla	Nome	Descrição clínica
NORM	Normal ECG	Ritmo sinusal sem achados patológicos relevantes
MI	Myocardial Infarction	Infarto do miocárdio (agudo, subagudo ou antigo)
STTC	ST/T Change	Alterações do segmento ST e/ou onda T (isquemia, distúrbios metabólicos)
CD	Conduction Disturbance	Distúrbios de condução atrioventricular e intraventricular
HYP	Hypertrophy	Hipertrofias atriais e/ou ventriculares

Fonte: adaptado de Wagner *et al.* (2020).

ou geração sintética de amostras (SMOTE).

3.1.2 Estratificação em Folds e Controle de Data Leakage

O PTB-XL fornece nativamente uma partição estratificada em dez folds (coluna `strat_fold`), concebida para suportar avaliação por validação cruzada com controle rigoroso de vazamento de dados. O critério de estratificação garante que todos os registros de um mesmo paciente sejam alocados no mesmo fold, de modo que os conjuntos de treino, validação e teste sejam disjuntos em nível de indivíduo — e não apenas em nível de registro. Esse ponto é relevante porque o PTB-XL contém múltiplos registros por paciente (razão média de 1,16 registros/paciente); sem tal controle, informações sobre um mesmo indivíduo poderiam vazar entre conjuntos, inflando artificialmente as estimativas de desempenho.

Neste trabalho, adota-se a divisão canônica sugerida pelos autores do dataset (WAGNER *et al.*, 2020):

- Folds 1 a 8 — conjunto de treino (17.418 registros; 79,9%);
- Fold 9 — conjunto de validação (2.183 registros; 10,0%);
- Fold 10 — conjunto de teste (2.198 registros; 10,1%).

Todos os parâmetros de normalização (medianas do *RobustScaler*, limites de winsorização, medianas de imputação por superclasse) são calculados exclusivamente nos folds de treino e aplicados, sem refit, ao conjunto de validação e teste. A coluna `split`, gerada no Entregável 1, codifica essa partição e serve de referência para todos os notebooks subsequentes do pipeline.

3.2 Ferramentas e Ambiente Computacional

Todo o pipeline foi implementado em **Python 3** com execução em **Jupyter Notebooks**, um por entregável, organizados sequencialmente de modo que cada notebook consuma exclusivamente os arquivos de saída do anterior. Essa estrutura garante rastreabilidade e reprodutibilidade completas: a reexecução de qualquer etapa a partir de seus arquivos de entrada produz resultados idênticos.

As bibliotecas utilizadas ao longo do pipeline são listadas a seguir, organizadas por função:

- **Acesso ao dataset:** `wfdb` para leitura dos arquivos de sinal no formato PhysioNet (pares `.dat/.hea`).
- **Manipulação de dados:** `numpy` para operações numéricas e manipulação de arrays multidimensionais; `pandas` para estruturação e análise de dados tabulares; `pyarrow/fastparquet` para leitura e escrita eficiente de arquivos `.parquet` nas etapas de extração e seleção de atributos.
- **Processamento de sinais:** `scipy.signal` para projeto e aplicação de filtros digitais (Butterworth, `filtfilt`), estimação espectral (Welch) e detecção de picos; `scipy.stats` para testes de hipótese, estatísticas descritivas e métricas de normalidade; `PyWavelets` para decomposição por transformada wavelet discreta (DWT) na extração de atributos de tempo-frequência.
- **Complexidade não-linear:** `antropy` para cálculo de entropia amostral (SampEn), dimensão fractal de Higuchi e expoente de DFA.
- **Aprendizado de máquina e seleção de atributos:** `scikit-learn` para normalização (`RobustScaler`, `StandardScaler`), redução de dimensionalidade (PCA, FastICA), regressão logística, Random Forest e validação cruzada; `skrebate` para o algoritmo ReliefF; `statsmodels` para testes estatísticos complementares e análise de variância.
- **Infraestrutura:** `joblib` para serialização eficiente de parâmetros de pipeline (filtros, limites de winsorização, scalers) e paralelização da extração de atributos; `tqdm` para barras de progresso em loops de processamento em lote; `matplotlib` e `seaborn` para visualizações.

As dependências completas estão listadas em `requirements.txt` na raiz do repositório, permitindo reprodução do ambiente via `pip install -r requirements.txt`.

3.3 Visão Geral do Pipeline

O pipeline implementado é composto por dez etapas sequenciais, denominadas Entregáveis 1 a 10 (E1–E10), que percorrem o caminho desde a leitura dos sinais brutos até a produção do dataset de atributos validado e pronto para classificação.

A Tabela 4 apresenta um resumo das dez etapas do pipeline, com os notebooks correspondentes e os principais arquivos de saída. As etapas são descritas em detalhe no Capítulo 4; a seguir apresenta-se uma síntese de cada uma.

O **E1** (Seção 4.1) documenta o protocolo de coleta, caracteriza o dataset nas dimensões demográfica e clínica, verifica a integridade da partição treino/validação/teste e inspeciona os sinais brutos por análise espectral. O **E2** (Seção 4.2) quantifica objetivamente a qualidade de cada registro por meio de oito métricas SQI combinadas em um classificador heurístico em cascata (Gatekeeper), produzindo a classificação G/A/P/U e excluindo do fluxo os registros inaceitáveis. O **E3** (Seção 4.3) conduz a análise estatística diagnóstica — verificação de normalidade, homocedasticidade e estrutura de correlação — que fundamenta a decisão metodológica de adoção de testes não paramétricos em todos os entregáveis subsequentes.

O **E4** (Seção 4.4) aplica a pipeline de pré-processamento: filtragem Butterworth bidirecional (passa-alta 0,5 Hz e passa-baixa 40 Hz) seguida de winsorização por percentis (0,5%–99,5%) por derivação, com limites calculados exclusivamente no treino. A qualidade é reavaliada por SQI após o processamento e os sinais são separados em bons (G/A) e ruins (P/U). O **E5** (Seção 4.5) segmenta os sinais limpos em dois níveis: registro de 10 s como instância principal e batimentos de 600 ms centrados no pico R detectado pelo algoritmo Pan-Tompkins. O **E6** (Seção 4.6) transforma os sinais segmentados em vetores de atributos distribuídos em cinco domínios: tempo, frequência, morfologia/HRV, tempo-frequência (DWT) e não-linear.

O **E7** (Seção 4.7) realiza a engenharia de atributos: remoção de quasi-constantes, imputação de valores ausentes, criação de features de segunda ordem (razões espectrais, normalizações por baseline NORM, deltas morfológicos) e normalização robusta. O **E8** (Seção 4.8) e o **E9** (Seção 4.9) são trilhas paralelas: o E8 aplica PCA (79 componentes, compressão de $\approx 72\%$) para produzir uma representação comprimida, enquanto o E9 seleciona 30 atributos originais interpretáveis por métodos de filtro, wrapper e embedded combinados via Borda Count ponderado. O **E10** (Seção 4.10) valida o dataset final por análise de multicolinearidade (VIF), separabilidade estatística (Kruskal-Wallis, Mann-Whitney, η^2), balanceamento de classes e curvas de densidade KDE; a remoção iterativa por VIF reduz o conjunto de 30 para 21 features sem

multicolinearidade severa, produzindo o arquivo `dataset_final_validado.parquet` pronto para o módulo de Reconhecimento de Padrões.

A Tabela 4 apresenta um resumo das dez etapas do pipeline, com os notebooks correspondentes e os principais arquivos de saída.

Tabela 4 – Resumo das etapas do pipeline de biossinais

#	Etapas	Notebook	Saída principal
1	Aquisição dos Biossinais	01_aquisicao_biossinais.ipynb	ptbxml_metadata_enriched
2	Avaliação da Qualidade (SQI)	02_qualidade_sinal_SQI.ipynb	ptbxml_com_sqi.csv
3	Análise Estatística Inicial	03_estatistica_inicial.ipynb	estatistica_inicial_res
4	Limpeza e Filtragem Digital	04_limpeza_dados.ipynb	sinais_bons_100hz.npy
5	Segmentação (Janelamento)	05_segmentacao.ipynb	batimentos_segmentados
6	Extração de Atributos	06_extracao_features_completo.ipynb	features_raw.parquet
7	Engenharia de Features	07_engenharia_features_completo.ipynb	features_engineered.parquet
8	Redução de Dimensionalidade	08_reducao_dimensionalidade_completo.ipynb	features_pca.parquet
9	Seleção de Atributos	09_selecao_atributos_completo.ipynb	features_selected.parquet
10	Validação Estatística Final	10_validacao_estatistica_final.ipynb	dataset_final_validado

Fonte: elaborado pelos autores.

3.4 Decisões Metodológicas Relevantes

O pipeline foi concebido de forma que cada decisão técnica relevante seja documentada com sua justificativa, de modo a garantir reprodutibilidade e rastreabilidade. A Tabela 5 apresenta uma síntese dessas decisões; os parágrafos seguintes desenvolvem as de maior impacto metodológico.

Taxa de amostragem de 100 Hz. O ECG de repouso carrega informação diagnóstica relevante na faixa de 0,05 a 40 Hz (KLIGFIELD *et al.*, 2007). Pelo Teorema de Nyquist, a frequência mínima de amostragem para reconstrução sem *aliasing* nessa banda é 80 Hz. A taxa de 100 Hz supera esse limiar com margem de 25%, garantindo a integridade do sinal, e ao mesmo tempo reduz em $5\times$ o custo computacional de todas as operações de leitura, filtragem e extração de atributos em relação à resolução original de 500 Hz disponível no PTB-XL.

Dispensa do filtro notch em 50 Hz. O processo de decimação de 500 para 100 Hz aplicado na geração do arquivo de baixa resolução do PTB-XL já inclui filtragem anti-*aliasing*, o que atenua fortemente o componente de 50 Hz antes da reamostragem. Adicionalmente, 50 Hz corresponde exatamente à frequência de Nyquist da série decimada, tornando inviável a construção de um filtro notch estável nessa frequência: qualquer filtro IIR projetado nesse ponto apresenta distorções de fase e amplitude inaceitáveis.

Adoção de testes não paramétricos. A verificação formal conduzida no Entregável 3 — por meio dos testes de Shapiro-Wilk, Kolmogorov-Smirnov, Levene e Bartlett — demonstrou que a hipótese de normalidade é rejeitada para todas as variáveis analisadas e que a homocedasticidade é violada na grande maioria delas, especialmente nas métricas derivadas dos sinais de ECG. Diante desse resultado, a adoção de testes paramétricos clássicos (ANOVA, teste t , correlação de Pearson como referência principal) não é justificada. Todos os entregáveis subsequentes que requerem comparação entre grupos utilizam o teste de Kruskal-Wallis (KRUSKAL; WALLIS, 1952) para k amostras, o Mann-Whitney U (MANN; WHITNEY, 1947) com correção de Bonferroni ou FDR-BH (BENJAMINI; HOCHBERG, 1995) para comparações pareadas, e a correlação de Spearman como medida padrão de associação. Quando o mesmo registro é avaliado antes e depois de uma transformação (e.g., filtragem no E4), emprega-se o teste de Wilcoxon pareado (WILCOXON, 1945).

RobustScaler antes de StandardScaler. O vetor de atributos brutos apresenta distribuições com caudas pesadas e outliers, conforme documentado no E3. O RobustScaler — que centraliza pela mediana e escala pelo IQR, sendo calculado exclusivamente nos folds de treino para evitar *data leakage* — torna cada *feature* invariante a valores extremos antes que qualquer análise multivariada seja conduzida. O StandardScaler adicional, aplicado nos Entregáveis 8 e 9, garante variância unitária, requisito de métodos como PCA, VIF e LDA.

A Tabela 5 sintetiza as principais decisões metodológicas adotadas ao longo do pipeline e suas respectivas justificativas.

Tabela 5 – Principais decisões metodológicas adotadas no pipeline

Decisão	Justificativa
Taxa de amostragem 100 Hz	Supera o critério de Nyquist para a banda diagnóstica do ECG (0,05–40 Hz) com margem de 25%; reduz custo computacional em $5\times$ em relação a 500 Hz.
Filtro notch 50 Hz dispensado	O downsampling original (500 $\rightarrow$ 100 Hz) já aplicou anti-aliasing; 50 Hz coincide com a frequência de Nyquist, impossibilitando filtro estável.
Limiar $SQI \geq 50\%$	Convenção do PTB-XL para diagnóstico positivo.
Winsorização por percentil 0,5–99,5%	Controla outliers de amplitude sem remoção de amostras; limites calculados no treino para evitar data leakage.
Segmentação Pan-Tompkins	Método de referência para detecção de pico R (PAN; TOMPKINS, 1985); período refratário adaptativo (60% do RR mediano) permite lidar com taquicardias.
RobustScaler antes de StandardScaler	RobustScaler (E7) torna o vetor invariante a outliers; StandardScaler adicional (E8/E9) garante variância unitária para PCA, VIF e LDA.
Testes não-paramétricos	Normalidade e homocedasticidade rejeitadas para todas as variáveis (E3); Kruskal-Wallis, Mann-Whitney e Spearman são os métodos padrão adotados.
Borda Count ponderado (ranking final)	Método de agregação robusto que não requer comparabilidade de escalas entre diferentes critérios de relevância.

Fonte: elaborado pelos autores.

4 RESULTADOS

4.1 Entregável 1 — Aquisição dos Biossinais

Esta etapa tem por objetivo documentar as condições originais de aquisição do PTB-XL, caracterizar a base de dados nas dimensões demográfica e clínica, e inspecionar os sinais brutos de ECG antes de qualquer transformação. Nenhuma filtragem ou alteração é aplicada aos sinais neste ponto; a saída é exclusivamente o arquivo de metadados enriquecidos `ptb-xl-metadata-enriched.csv`, que serve de entrada direta para todos os notebooks subsequentes do pipeline.

Protocolo de Aquisição e Taxa de Amostragem

O PTB-XL foi coletado entre novembro de 1984 e junho de 2001 no *Physikalisch-Technische Bundesanstalt* (PTB), Berlim, com eletrocardiógrafo Schiller AG em 11 modelos distintos distribuídos por 51 pontos de coleta. Os registros totalizaram 21.799 ECGs de 10 s de 18.869 pacientes, digitalizados originalmente a 400 Hz, reamostrados para 500 Hz e disponibilizados também a 100 Hz.


Processo de Anotação e Critério de Diagnóstico Positivo

O processo de rotulagem do PTB-XL seguiu múltiplas etapas: laudo inicial por cardiologista (ou gerado automaticamente pelo dispositivo), conversão para códigos SCP-ECG, revisão por segundo especialista e, nos casos mais complexos, confirmação por terceiro avaliador. Ao todo, 73,7% dos registros (16.056) possuem validação humana confirmada, enquanto 31,3% (6.813) tiveram o laudo inicial gerado automaticamente pelo equipamento.

Análise Demográfica

A Figura 1 apresenta a distribuição de idade e sexo dos pacientes do PTB-XL. Após substituição dos valores codificados como 300 (convenção adotada pelo dataset para pacientes com 90 anos ou mais, que impede identificação precisa) e remoção de registros sem informação de idade, a distribuição resultante apresenta mediana próxima a 62 anos, com assimetria positiva e cauda à esquerda — padrão consistente com um dataset hospitalar de ECG de repouso, no qual pacientes mais idosos predominam.

Figura 1 – Distribuição demográfica dos pacientes do PTB-XL: histograma de idades por sexo (esq.) e proporção por sexo (dir.)



Fonte: elaborado pelos autores.

Distribuição das Superclasses Diagnósticas

A Figura ?? ilustra a distribuição de registros por superclasse. NORM é a categoria mais frequente, seguida de MI e STTC; HYP apresenta o menor volume absoluto.

Verificação Anti-Leakage entre Folds

A integridade da partição foi verificada explicitamente: confirmou-se que nenhum `patient_id` aparece simultaneamente em folds distintos. Trata-se de uma checagem necessária porque o PTB-XL contém múltiplos registros por paciente — proporção média de 1,16 registros/paciente — o que, sem o controle adequado, poderia introduzir vazamento de informação entre treino e teste e comprometer a validade das métricas de desempenho dos classificadores.

Análise Espectral dos Sinais Brutos

A inspeção espectral foi conduzida por meio do método de Welch sobre uma amostra representativa de registros de cada superclasse. A estimação de densidade espectral de potência (PSD) confirmou que a maior parte da energia dos sinais está concentrada abaixo de 25 Hz, com pico pronunciado na faixa do complexo QRS (5–25 Hz).

Enriquecimento dos Metadados e Arquivo de Saída

Ao término da análise exploratória, o DataFrame de metadados foi enriquecido com a coluna `split` — que codifica a partição de cada registro em treino, validação ou teste com base no fold estratificado — e com colunas derivadas que mapeiam os códigos SCP-ECG brutos para as superclasses (`superclasses_clean`) e ritmo (`rhythm_clean`) em formato de lista. A coluna original `scp_codes` foi preservada para garantir flexibilidade em eventuais redefinições de rótulos em etapas futuras. Registros com anotação de problemas de qualidade

Tabela 6 – Distribuição dos registros por conjunto após a partição treino/validação/teste

Conjunto	Registros	% do total
Treino (folds 1–8)	17.418	79,9%
Validação (fold 9)	2.183	10,0%
Teste (fold 10)	2.198	10,1%
Total	21.799	100%

Fonte: elaborado pelos autores.

na coluna `has_quality_issues` totalizam 5.010, o equivalente a 22,98% do total, sinalizando a necessidade da etapa de avaliação objetiva de qualidade implementada no Entregável 2. O arquivo `ptbxl_metadata_enriched.csv` — com 21.799 linhas e metadados consolidados — é a entrada direta do notebook de avaliação SQI.

4.2 Entregável 2 — Avaliação da Qualidade do Sinal (SQI)

Esta etapa quantifica objetivamente a qualidade de cada um dos 21.799 registros do PTB-XL por meio de um conjunto de métricas SQI, combinadas em um classificador heurístico em cascata. A avaliação é conduzida sobre os sinais brutos — sem qualquer filtragem prévia —, de modo que os índices reflitam fielmente as condições de aquisição originais.

Métricas Implementadas

Foram implementadas oito métricas distribuídas em quatro categorias. Em todos os casos, as métricas são calculadas por derivação e depois agregadas (média ou mediana) para produzir um único valor por registro. **Estatísticas de ordem superior (hosSQI):** definido como $hosSQI = |sSQI| \times kSQI / 5$, onde $sSQI$ e $kSQI$ são a assimetria e a curtose do sinal, respectivamente. Valores superiores a 0,8 já caracterizam sinais com boa integridade morfo-

lógica. **Domínio da frequência (pSQI, basSQI, SNR, entropia espectral):** o pSQI mede a concentração de energia na banda 5–15 Hz; o basSQI, a proporção de energia acima de 1 Hz; o SNR é calculado como a razão entre o sinal filtrado (0,5–40 Hz) e o ruído residual em dB; a entropia espectral é calculada a partir da PSD normalizada via Welch e normalizada pelo máximo teórico. **Continuidade (flat ratio, flatline flag):** flat ratio é a proporção de amostras com variação absoluta menor que 10^{-3} ; a flatline flag sinaliza segmento contínuo constante com duração $\geq 1,5$ s. **Regularidade dos batimentos (qSQI):** aproximação baseada na variabilidade relativa dos intervalos RR, $qSQI = 1 - \sigma_{RR}/\bar{RR}$. **Consistência multicanal (rinter):** média das correlações de Pearson entre todos os pares de derivações com desvio padrão $> 10^{-6}$.

Classificador Gatekeeper

O Gatekeeper opera em dois estágios sequenciais. No primeiro (*hard gate*), os critérios de exclusão imediata definem a classe U: flat_ratio $> 0,25$, SNR < 0 dB, presença de flatline contínuo $\geq 1,5$ s ou qSQI $< 0,6$. Os limiares iniciais foram extraídos da literatura e refinados por otimização univariada dentro de uma faixa de $\pm 10\%$ do valor original. O critério de otimização é um escore balanceado:

$$\text{Score} = \frac{\text{registros limpos} \rightarrow G/A}{\text{total limpos}} + \frac{\text{registros com problema} \rightarrow P/U}{\text{total com problema}} \quad (4.1)$$

A Tabela ?? apresenta os limiares originais e os valores otimizados resultantes.

O padrão dos ajustes é consistente com a premissa do classificador: limiares associados a ruído tratável (SNR, basSQI) foram relaxados — maior tolerância a degradações corrigíveis —, enquanto limiares relacionados à integridade estrutural do sinal (qSQI, entropia espectral, hosSQI, rinter, pSQI) foram endurecidos, reforçando a distinção entre sinais com morfologia fisicamente plausível e sinais estruturalmente comprometidos.

Distribuição das Classes de Qualidade

A Tabela ?? apresenta a distribuição dos 21.799 registros pelas quatro categorias após a aplicação do Gatekeeper com limiares otimizados. Nenhum registro atingiu a categoria G, o que indica que os limiares de excelência são, na prática, raramente satisfeitos em dados clínicos coletados ao longo de mais de uma década com diferentes equipamentos e condições. A soma G + A corresponde a 75,6% do dataset — parcela que avança para as etapas subsequentes do pipeline sem processamento corretivo adicional nesta fase. A Tabela 7 apresenta os resultados.

Dos registros sem problema anotado, 77,6% foram classificados como G ou A — taxa de falsa


Tabela 7 – Distribuição das classes SQI por presença de problema anotado nos metadados (%)

Grupo	A (%)	P (%)	U (%)
Sem problema anotado (16.789 reg.)	77,6	13,9	8,5
Com problema anotado (5.010 reg.)	68,7	20,7	10,7

Fonte: elaborado pelos autores.

rejeição de apenas 22,4%. Dos registros com problema anotado, 31,3% foram classificados como P ou U. A análise do SNR por derivação evidencia que os canais precordiais V1–V3

Figura 2 – Distribuição do SNR por classe de qualidade e por derivação



Fonte: elaborado pelos autores.

apresentam maior variabilidade e maior incidência de outliers negativos, possivelmente pela maior suscetibilidade a ruído de movimento e variações de posicionamento torácico.

4.3 Entregável 3 — Análise Estatística Inicial

Esta etapa avança da caracterização exploratória realizada no Entregável 1 para uma abordagem diagnóstica e metodológica, cujo objetivo é qualificar estatisticamente os dados e orientar as decisões analíticas dos entregáveis subsequentes. Enquanto o E1 respondia à pergunta “o que temos nas mãos?”, o E3 responde a uma pergunta distinta: “quais são os pressupostos dos nossos dados e quais métodos podemos aplicar com segurança?”. A estratificação das mesmas variáveis pelas cinco superclasses diagnósticas — aplicada apenas sobre registros com rótulo único ($n_{superclasses} = 1$) para evitar ambiguidade multi-label — revela padrões clinicamente relevantes. A variável mais informativa é a **idade**: pacientes classificados como NORM apresentam mediana de 54 anos ($Q1 = 40$; $Q3 = 65$), ao passo que as classes patológicas (MI, CD, STTC e HYP) concentram-se em torno de 64–65 anos. A análise temporal do volume de coleta e da taxa de laudos automáticos, apresentada na Figura ??, revela uma adoção tecnológica em duas fases. Entre 1989 e 1990, a proporção de exames com laudo automático saltou de aproximadamente 0,3% para 27,4%, evidenciando uma incorporação inicial acelerada de sistemas digitais de análise de ECG. O volume absoluto de coletas atingiu seu pico nos anos intermediários da década de 1990, com queda gradual no final do período, possivelmente associada à maturidade do banco de dados e a mudanças institucionais.

Estatística Descritiva dos Sinais

A caracterização quantitativa dos sinais de ECG foi conduzida sobre uma **amostra estratificada de 500 registros por superclasse** (2.500 no total), selecionada exclusivamente entre registros de qualidade A pertencentes aos folds de treino (1–8). **Amplitude (RMS e P2P)**. As derivações precordiais V2–V5 apresentaram os maiores valores medianos de amplitude em todas as superclasses, comportamento esperado dado o alinhamento dessas derivações com o vetor principal de despolarização ventricular. As métricas RMS e P2P mostraram-se altamente coerentes entre si: regiões de maior RMS corresponderam invariavelmente a maiores valores de P2P. **Energia**. A análise da energia por registro completo confirmou e expandiu os achados de amplitude. HYP apresentou a maior mediana de energia (0,754), seguida de CD (0,597) com alta variabilidade interna (desvio padrão de 1,461 e máximo de até 15,714), indicando grande heterogeneidade nos tipos de distúrbio de condução. NORM, MI e STTC concentraram-se na faixa de 0,35–0,38, embora MI apresente média ligeiramente superior (0,442) e maior dispersão,

sugerindo que alguns padrões de infarto produzem atividade elétrica anormalmente intensa. HYP apresentou a maior mediana global de STD (0,201) e CD a segunda maior (0,176), com dispersão mais elevada evidenciando heterogeneidade morfológica. **Morfologia (*kurtosis* e *skewness*)**. Todas as classes apresentaram *kurtosis* elevada (tipicamente acima de 10), reflexo dos picos acentuados do complexo QRS. HYP e STTC exibiram valores mais altos nas derivações V5 e V6, enquanto CD apresentou *kurtosis* sistematicamente menor — indicativo de sinais morfolologicamente mais dispersos e menos concentrados, compatível com bloqueios de ramo e outras alterações de condução. **Síntese integrada.** A padronização conjunta das métricas por *z-score* evidencia que HYP é a classe com perfil sistematicamente acima da média em todas as dimensões (amplitude, variabilidade, energia e morfologia), ao passo que MI é a mais “silenciosa” em amplitude, variabilidade e energia.

Testes de Normalidade

Os testes de Shapiro-Wilk (SW) e Kolmogorov-Smirnov (K-S) foram aplicados a um conjunto representativo de variáveis, incluindo metadados demográficos (idade, peso, altura) e métricas derivadas dos sinais (RMS, P2P, STD, *skewness*, *kurtosis* e energia). Para o SW, utilizou-se uma subamostra aleatória de até 5.000 observações, respeitando as limitações computacionais do método; o K-S foi aplicado sobre a série completa após padronização. **Resultado:** a hipótese nula de normalidade foi rejeitada ($p < 0,05$) em ambos os testes para todas as variáveis analisadas. As variáveis demográficas apresentaram estatísticas de Shapiro-Wilk relativamente próximas de 1 ($W \approx 0,95\text{--}0,98$), indicando distribuições com desvios moderados da gaussiana — provavelmente assimetrias leves e presença de valores extremos, como o indivíduo de peso de 5 kg e o de altura de 6 cm identificados na base. As métricas de amplitude e variabilidade do sinal apresentaram $W \approx 0,75\text{--}0,89$, revelando caudas mais pesadas e assimetria mais pronunciada. A energia total exibiu o comportamento mais extremo ($W \approx 0,49$), compatível com uma distribuição fortemente assimétrica à direita típica de medidas acumulativas. As métricas morfológicas (*skewness* e *kurtosis* medianos) exibiram excelente aderência à reta diagonal na região central (Q1–Q3), com desvios concentrados nas extremidades. A energia total apresentou o afastamento mais acentuado, com pontos deslocados significativamente acima da diagonal na cauda direita.

Testes de Homocedasticidade

Os testes de Levene (centrado na mediana, robusto à não normalidade) e Bartlett (sensível à normalidade, mantido como referência) foram aplicados às mesmas variáveis, com os grupos definidos pelas cinco superclasses diagnósticas. Para as variáveis demográficas, o comportamento foi parcialmente distinto: peso e altura não apresentaram evidência de heterocedasticidade segundo o teste de Levene ($p \geq 0,05$), ao passo que o teste de Bartlett rejeitou a homogeneidade para ambas — diferença esperada dada a maior sensibilidade do Bartlett a desvios da normalidade. Para as métricas derivadas dos sinais, a **heterocedasticidade foi generalizada**: todas as variáveis (RMS, P2P, STD, *skewness*, *kurtosis* e energia) rejeitaram a hipótese de variâncias iguais com $p \ll 0,001$ em ambos os testes.


Análise de Correlação

As matrizes de correlação de Pearson e Spearman foram construídas com base em métricas agregadas por registro (mediana entre derivações para RMS, P2P, STD, *skewness* e *kurtosis*; energia total por registro), combinadas com as variáveis demográficas disponíveis para os registros da amostra estratificada. O resultado mais expressivo é a **correlação quase perfeita entre RMS e STD** ($\rho \approx 1,0$ em Pearson e Spearman), evidenciando que ambas as métricas capturam essencialmente a mesma informação — a magnitude das variações do sinal — e são, portanto, redundantes. RMS e P2P apresentaram correlação forte ($\rho \approx 0,84\text{--}0,87$), e a energia mostrou correlação moderada a forte com esse bloco ($\rho \approx 0,56$ em Pearson e até $0,77$ em Spearman). As métricas morfológicas (*skewness* e *kurtosis*) apresentaram correlação moderada entre si ($\rho \approx 0,44\text{--}0,47$) e baixa correlação com o bloco energético, confirmando que descrevem uma **dimensão complementar e relativamente independente** do sinal. As variáveis demográficas apresentaram correlações fracas a moderadas com as métricas de sinal (a mais elevada sendo $\rho \approx 0,18$ para idade vs. RMS em Spearman), indicando que a variabilidade observada no ECG é predominantemente explicada por fatores clínicos e fisiológicos específicos, não capturados diretamente por essas variáveis.

Decisão Metodológica e Conexão com o Entregável 4

A integração dos resultados desta etapa conduz a uma decisão metodológica clara e documentada: dado que a normalidade foi rejeitada para todas as variáveis e a homocedasticidade

Figura 3 – Matrizes de correlação de Pearson e Spearman entre variáveis demográficas e métricas do sinal de ECG



Fonte: elaborado pelos autores.

foi amplamente violada nas métricas de sinal, os pressupostos necessários para o uso seguro de testes paramétricos clássicos (ANOVA, teste t , correlação de Pearson como referência principal) não são atendidos. Adota-se, portanto, a utilização predominante de **métodos não paramétricos** em todos os entregáveis subsequentes: Kruskal-Wallis para comparação de k grupos, Mann-Whitney U para comparações pareadas e correlação de Spearman como medida principal de associação. A redundância identificada entre RMS, STD e P2P orienta diretamente a etapa de engenharia de *features* (E7): pelo menos uma dessas métricas pode ser removida sem perda de informação, reduzindo a dimensionalidade do vetor de atributos. A estrutura de correlação em blocos também informa a análise de multicolinearidade conduzida no E10.

4.4 Entregável 4 — Limpeza e Filtragem Digital dos Sinais

Esta etapa realiza a primeira intervenção direta nos sinais do PTB-XL. Enquanto o Entregável 2 apenas avaliou e classificou a qualidade dos registros — excluindo os inaceitáveis (U) sem modificar nenhum sinal —, o E4 aplica uma pipeline de pré-processamento sobre os 19.840 registros restantes (categorias G, A e P), buscando reduzir artefatos tratáveis sem comprometer a morfologia das ondas cardíacas.

Inventário de Problemas e Plano de Ação

A construção do plano de limpeza partiu da integração dos resultados dos Entregáveis 2 e 3. Distorções morfológicas estruturais — aquelas associadas a *hosSQI* baixo sem causa

espectral identificável — não possuem correção direta e são tratadas apenas indiretamente via estabilização estatística.

Filtragem Digital

Os filtros foram implementados com o modelo Butterworth (resposta maximamente plana na banda passante, sem *ripple*) e aplicados via `filtfilt` — filtragem bidirecional que cancela a distorção de fase, preservando o alinhamento temporal das ondas P, QRS e T. A cascata passa-alta + passa-baixa define implicitamente um filtro passa-faixa de 0,5 a 40 Hz, intervalo que concentra toda a informação diagnóstica relevante do ECG de repouso (KLIGFIELD *et al.*, 2007). A interferência de rede elétrica em 50 Hz não requer tratamento adicional. O processo de decimação de 500 para 100 Hz na geração do PTB-XL inclui filtragem anti-*aliasing* que já atenua esse componente, e a coincidência entre 50 Hz e a frequência de Nyquist da série decimada torna inviável a construção de qualquer filtro notch estável nesse ponto. A validação espectral conduzida em amostras aleatórias confirmou ausência de energia significativa em 50 Hz nos sinais brutos, corroborando a hipótese de atenuação prévia. A Figura ?? apresenta o espectro médio calculado sobre 100 registros antes e depois da filtragem: observa-se atenuação consistente abaixo de 0,5 Hz e acima de 40 Hz, com preservação do platô espectral intermediário.

A comparação no domínio do tempo, apresentada na Figura ??, evidencia estabilização da linha de base em torno de 0 mV e suavização de componentes de alta frequência, com preservação clara da morfologia P-QRS-T em diferentes registros.

Winsorização por Derivação

Os limites de winsorização foram calculados sobre os valores do sinal filtrado de 2.500 registros amostrados aleatoriamente dos folds de treino (1–8), de forma independente para cada uma das 12 derivações. Contribui indiretamente para a estabilização de métricas de ordem superior (especialmente kurtosis), cujos valores elevados no E3 foram associados à presença de outliers e não necessariamente a características morfológicas dos sinais. Para cada grupo, foram calculadas as métricas RMS global e energia total, comparadas pelo **teste de Wilcoxon pareado** (adequado a dados não normais, conforme decisão metodológica do E3) e quantificadas pelo **Cohen's *d*** sobre as diferenças pareadas. Os resultados, apresentados na Tabela ??, indicam rejeição consistente da hipótese nula ($p < 0,001$) em todos os grupos, confirmando que a pipeline produz modificações estatisticamente significativas. A magnitude das alterações, medida por

Cohen's d , varia sistematicamente conforme o tipo de artefato: O grupo com *baseline drift* apresentou o maior efeito (grande), coerente com a eficácia do filtro passa-alta na remoção direta desse tipo de artefato.

Reavaliação SQI e Separação dos Sinais

Após o processamento em lote de todos os 19.840 registros, as métricas SQI foram recalculadas sobre os sinais limpos utilizando exatamente os mesmos critérios e limiares do Entregável 2. A Tabela 8 apresenta a comparação das distribuições antes e depois. Os resultados

Tabela 8 – Distribuição das categorias de qualidade SQI antes e depois da aplicação da pipeline de limpeza

Categoria	Antes (qtd.)	Antes (%)	Depois (qtd.)	Depois (%)
G	0	0,0	–	–
A	16.475	83,0	–	–
P	3.365	17,0	–	< 2
U	0*	0,0	–	–

Fonte: elaborado pelos autores. *Registros U já excluídos pelo E2.

revelam dois movimentos simultâneos: uma redução expressiva da classe P (de $\approx 17\%$ para menos de 2%), com migração majoritária para A e surgimento de registros G — inexistentes na avaliação original; e um aumento da classe U, interpretado não como degradação introduzida pela pipeline, mas como refinamento da avaliação: a remoção de componentes de ruído que antes mascaravam distorções estruturais expõe sinais intrinsecamente comprometidos que passam a ser corretamente identificados. A matriz de transição, apresentada na Figura ??, confirma que a maioria dos sinais A permanece em A (estabilidade) e que as transições positivas ($P \rightarrow A$ e $A \rightarrow G$) superam as negativas.

A análise qualitativa de casos $P \rightarrow G$ confirmou, no domínio do tempo e da frequência, que sinais previamente degradados por *drift* e ruído passam a exibir morfologia limpa e concentração espectral na faixa fisiológica após o processamento.

Saídas e Conexão com o Entregável 5

Ao término do processamento em lote, os sinais são divididos em dois arquivos: `sinais_bons_100hz.npy`, contendo os registros reclassificados como G ou A, que avançam diretamente para a segmentação; e `sinais_ruins_100hz.npy`, com os registros P ou U, mantidos separados para fins de análise de sensibilidade.

4.5 Entregável 5 — Segmentação (Janelamento)

Esta etapa transforma os registros de 10 s produzidos pelo Entregável 4 em unidades analíticas adequadas para a extração de atributos. Enquanto os entregáveis anteriores avaliaram qualidade (E2), caracterizaram estatisticamente (E3) e limpam os sinais (E4), o foco do E5 é *estrutural*: definir como o sinal será dividido antes da extração de *features*. **Nível 1 — Instância Principal: Registro de 10 s.** Cada registro completo de 10 segundos ($1.000 \text{ amostras} \times 12 \text{ derivações}$) constitui uma instância independente do *dataset*. Essa escolha preserva a unidade clínica original do PTB-XL — concebido em torno do exame de ECG de repouso de 10 s — e garante três propriedades fundamentais: independência entre instâncias, ausência de *label inflation* e consistência com a divisão estratificada em folds definida no Entregável 1. **Nível 2 — Segmentação Auxiliar: Batimento de 600 ms.** Determinadas classes de *features* — morfologia das ondas cardíacas e métricas de variabilidade de frequência cardíaca (HRV) — não podem ser extraídas de forma confiável sobre o registro completo de 10 s. A Tabela ?? sintetiza a decisão.

Verificação de Integridade e Propagação de Metadados

Antes da segmentação, foi verificada a correspondência biunívoca entre o índice dos sinais no array NumPy e o `ecg_id` no *DataFrame* de metadados. A distribuição dos 17.744 registros pelos dez folds mostrou-se equilibrada, com variações entre 1.740 (fold 5) e 1.808 (fold 3) registros — flutuações esperadas dado o processo de remoção de sinais P e U no E4. A inspeção visual dos sinais em 15 exemplos — três por superclasse, na derivação DII — evidenciou a eficácia da limpeza realizada no E4: o *drift* de *baseline*, presente com frequência nos sinais brutos, foi praticamente eliminado em todos os registros.

Implementação da Segmentação por Batimento

O detector Pan-Tompkins foi implementado conforme descrito na Seção 2.4.1, com os seguintes parâmetros: filtro Butterworth passa-banda de ordem 2 com cortes em 5 e 15 Hz (implementado via `filtfilt`), janela de integração de $N_w = 15$ amostras (150 ms a 100 Hz), limiar de proeminência definido como 30% do percentil de 95% do sinal integrado e período refratário adaptativo de 60% do RR mediano estimado na primeira passagem, com piso de 150 ms. A janela de batimento extrai 20 amostras pré-pico e 40 amostras pós-pico em todas as 12 derivações simultaneamente. O processamento em lote dos 17.744 registros foi concluído


com cobertura total: **nenhum registro** apresentou falha completa na detecção de picos R. Esse resultado reflete diretamente a eficácia do pipeline de exclusão do E2 — registros com segmentos prolongados de sinal constante (*flatline*) ou degradação estrutural grave foram descartados como categoria U — de modo que os registros desta etapa possuem integridade mínima garantida.

O total de 211.442 batimentos corresponde a uma média de aproximadamente 11,9 batimentos por registro, valor plenamente consistente com a faixa fisiológica de 6 a 15 batimentos esperada para frequências cardíacas entre 60 e 100 bpm em registros de 10 s. Dos 17.744 registros, 3.180 (17,9%) apresentaram risco de sobreposição de janelas — intervalo RR mínimo inferior a 600 ms —, comportamento esperado em cenários de taquicardia ou ritmos irregulares e sinalizados pelo *overlap flag* para rastreabilidade nas etapas seguintes.

Estabilidade intra-janela. Sobre uma amostra aleatória de 5.000 registros (aproximadamente 28% do total), foram calculadas a *Zero Crossing Rate* (ZCR) e a variância do sinal na derivação DII. O ZCR médio foi de 0,096 (mediana: 0,089), situado confortavelmente na faixa esperada para sinais de ECG fisiológicos (0,05–0,30), sem evidência de sinais degenerados por excesso de suavização ou por contaminação dominante de ruído de alta frequência. A variância média foi de $1,757 \times 10^{-2} \text{ mV}^2$ (mediana: $1,489 \times 10^{-2} \text{ mV}^2$), bem acima do limiar crítico de $1 \times 10^{-4} \text{ mV}^2$ que sinalizaria sinais planos ou saturados. Apenas 46 registros apresentaram ZCR abaixo do percentil de 1% da distribuição — possíveis casos residuais de baixa atividade ou morfologia atípica —, e **nenhum** registro exibiu variância inferior ao limiar crítico. A análise dos boxplots de ZCR e variância por superclasse, apresentados na Figura 4, revela um padrão clinicamente coerente.

Variância inter-janela. Para cada registro, foram calculadas a variabilidade do

Figura 4 – ZCR e variância por superclasse diagnóstica — análise de estabilidade intra-janela (derivação DII, amostra de 5.000 registros)



Fonte: elaborado pelos autores.

RMS entre batimentos (*var_intra_beat*) e o desvio padrão dos intervalos RR (*SDNN*) — métricas de HRV de curto prazo amplamente utilizadas na literatura de análise cardíaca (Task

Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology, 1996). As estatísticas medianas por superclasse, apresentadas na Tabela 9, revelam diferenças sistemáticas na dinâmica temporal do ritmo: a classe NORM apresentou o maior RR médio (846 ms, equivalente a ≈ 71 bpm), ao passo que STTC apresentou o menor (785 ms, ≈ 76 bpm). O teste de Kruskal-Wallis — método não paramétrico adotado como

Tabela 9 – Métricas inter-janela medianas por superclasse diagnóstica

Superclasse	N batimentos (med.)	RR médio (ms)	SDNN (ms)	Var. intra-batimento
NORM	10	846	24	0,00
MI	11	815	25	0,01
CD	11	798	24	0,01
STTC	11	785	25	0,01
HYP	11	807	22	0,01

Fonte: elaborado pelos autores.

padrão neste trabalho desde o Entregável 3 (KRUSKAL; WALLIS, 1952) — foi aplicado às distribuições da variância inter-batimento e do SDNN entre as cinco superclasses. Ambas as métricas produziram rejeição consistente de H_0 com $p < 0,001$ (estatísticas $H = 468,46$ e $H = 47,80$, respectivamente), confirmando que as diferenças observadas não são atribuíveis a variação aleatória. **Sobreposição visual de batimentos.** A Figura ?? apresenta os perfis médios e individuais dos batimentos segmentados por superclasse na derivação DII. Em algumas classes patológicas, inversões de polaridade — reflexo de alterações no eixo elétrico cardíaco — contribuem para a dispersão observada. **Diagramas de Poincaré.** A Figura ?? apresenta os diagramas de Poincaré dos intervalos RR — que plotam o intervalo RR_{n+1} em função de RR_n — por superclasse. Todos os padrões são coerentes com o conhecimento clínico sobre as respectivas condições e reforçam a validade da detecção de picos R pelo algoritmo Pan-Tompkins: os intervalos RR estimados reproduzem comportamentos fisiológicos esperados, sem artefatos sistemáticos de detecção.

Saídas e Conexão com o Entregável 6

O E5 estrutura o *pipeline* em dois fluxos paralelos que alimentam o Entregável 6: (i) o **fluxo de features globais**, alimentado pelos registros de 10 s carregados via *mmap* a partir de `sinais_bons_100hz.npy`, sobre os quais serão calculadas *features* de domínio do tempo (RMS, variância, ZCR, *skewness*, *kurtosis*), frequência (PSD por banda via Welch) e não lineares (entropia amostral, dimensão fractal de Higuchi, DFA); e (ii) o **fluxo de features morfológicas**,

alimentado pela matriz `batimentos_segmentados.npy`, sobre a qual serão calculadas métricas de forma (amplitude das ondas, duração do QRS, desvio do segmento ST) e de HRV, parcialmente pré-calculadas nesta etapa e armazenadas em `metricas_inter_janela.csv`.

4.6 Entregável 6 — Extração de Atributos

Esta etapa transforma os sinais de ECG limpos (E4) e segmentados (E5) em um conjunto estruturado de variáveis numéricas utilizáveis por algoritmos de aprendizado de máquina. A estratégia adotada é hierárquica e híbrida: atributos globais são extraídos sobre o registro de 10 s em todas as 12 derivações; atributos morfológicos e de variabilidade de ritmo são calculados por batimento individual e agregados ao nível do registro, de modo que o número de instâncias permanece em 17.744 e a independência amostral estabelecida no Entregável 1 é preservada.


Domínio do Tempo — 84 atributos (12 derivações $\times$ 7)

Sete estatísticas descritivas são extraídas sobre os 1.000 pontos de cada derivação: RMS, MAV, variância, P2P, ZCR, *skewness* e *kurtosis*. O processamento em lote dos 17.744 registros é realizado em paralelo via `joblib` e conclui em aproximadamente 28 s. Os valores medianos de RMS situam-se em torno de 0,12 mV para derivações de membros, com *kurtosis* globalmente elevada (média $\approx 13,6$ na derivação I), consistente com os picos abruptos do complexo QRS identificados no Entregável 3. A análise dos boxplots de RMS por superclasse e derivação evidencia que a classe HYP apresenta medianas sistematicamente superiores — reflexo do aumento de amplitude associado à hipertrofia ventricular — e que a classe MI exhibe os menores valores, compatíveis com a redução de massa miocárdica ativa.

Domínio da Frequência — 84 atributos (12 derivações $\times$ 7)

A PSD é estimada pelo método de Welch com segmento de 256 amostras (resolução de $\approx 0,39$ Hz), sobreposição de 50% e janela de Hann. Para cada derivação, são extraídas: potência nas bandas PT (0,5–5 Hz), QRS (5–25 Hz) e total (0,5–40 Hz), a razão QRS/Total, e três descritores de forma da PSD (frequência de pico, mediana e centroide espectral).

Figura 5 – PSD média estimada via Welch na derivação DII por superclasse diagnóstica



Fonte: elaborado pelos autores.

Morfologia e HRV — 25 atributos

Os atributos morfológicos são extraídos sobre os 211.442 batimentos segmentados no Entregável 5, nas derivações DII e V5. Quatro grandezas são medidas por batimento: amplitude R, duração do QRS (por cruzamento de limiar), amplitude do segmento ST (amostras 36–46 da janela) e amplitude da onda T (pico nas amostras 40–60). A duração mediana do QRS em V5 (`morph_qrs_width_ms_V5_median`) é a *feature* mais discriminativa do grupo: a classe CD apresenta valores significativamente superiores às demais, com mediana e primeiro quartil frequentemente acima dos quartis superiores das outras classes — comportamento diretamente alinhado com o alargamento do QRS em bloqueios de ramo.

Domínio Tempo-Frequência (DWT) — 32 atributos

A decomposição por DWT com família db4 em 4 níveis é aplicada sobre as derivações DII e V5 de cada registro. Para cada uma das cinco sub-bandas (A_4 , D_4 , D_3 , D_2 , D_1) e cada derivação, são extraídos energia, energia relativa e entropia de Shannon; uma razão QRS wavelet complementa o conjunto, totalizando 32 *features*. A sub-banda D_3 (12,5–25 Hz) concentra a maior fração da energia total na maioria dos registros, confirmando que o principal conteúdo do complexo QRS cai nessa faixa. A sub-banda A_4 (0–6,25 Hz) captura variabilidade mais lenta e apresenta maior spread entre registros, refletindo diferenças na energia das ondas P e T e em componentes de baixa frequência.

Dinâmica Não-Linear — 6 atributos

As *features* não-lineares são extraídas sobre a derivação DII (Higuchi FD) e sobre a série RR (DFA, SampEn, SD1, SD2, SD1/SD2). A dimensão fractal de Higuchi situa-se entre 1,058 e 1,896 no dataset, com valores dentro do intervalo $[1,0; 2,0]$ definido matematicamente para séries não-lineares. A SampEn sobre a série RR apresentou taxa de NaN de 100% — o registros com menos de 8 batimentos detectados inviabilizam o cálculo confiável —, razão pela qual esse atributo é documentado como ausente e tratado no Entregável 7.

Consolidação e Sanidade do Dataset

A unificação dos cinco grupos de *features* pelo índice `ecg_id` produz o arquivo `features_raw.parquet` com 17.744 linhas e **231 atributos**, distribuídos conforme a Tabela ???. O *sanity check* revelou 19.222 valores ausentes no dataset, correspondendo a apenas 0,46% das células totais. Os valores ausentes concentram-se em 12 colunas: `nonlin_sampen_rr` (100% NaN, conforme esperado pela insuficiência de batimentos para o cálculo), seguido pelas métricas do diagrama de Poincaré (SD1, SD2, SD1/SD2, com NaN em $\approx 2,6\text{--}2,8\%$ dos registros) e, em menor proporção, por `hrv_rmssd`, `hrv_sdRR` e algumas *features* de ST e assimetria do QRS ($< 0,03\%$). A análise de correlação cruzada entre domínios identificou 66 *features* envolvidas em pares com $|r| > 0,90$ entre domínios distintos, evidenciando redundância estrutural que será formalmente tratada no Entregável 7. A principal sobreposição ocorre entre as *features* de variância temporal (`time_var_*`) e potência total espectral (`freq_total_power_*`), que são matematicamente equivalentes para sinais centrados — ambas medem essencialmente a energia do sinal na mesma escala.

O arquivo `feature_catalog.csv` documenta todos os 231 atributos com domínio, média, desvio padrão e proporção de NaN, servindo de referência para as etapas subsequentes.

4.7 Entregável 7 — Engenharia de Features

Esta etapa opera sobre o arquivo `features_raw.parquet` gerado pelo Entregável 6 — com 17.744 instâncias e 231 atributos — e tem por objetivo produzir um vetor de *features* limpo, enriquecido e normalizado, pronto para as trilhas paralelas de redução de dimensionalidade (E8) e seleção de atributos (E9). **Atributos quasi-constant**. A verificação de variância inferior a 10^{-6} sobre o dataset completo não identificou nenhum atributo nessa condição. Esse resultado

é esperado: o pipeline de extração do E6 abrange domínios heterogêneos (tempo, frequência, morfologia, tempo-frequência, não linear), cada um com variabilidade intrínseca proveniente da diversidade clínica do PTB-XL — 71 classes diagnósticas em cinco superclasses. A ausência de atributos quasi-constantes confirma que nenhuma das 231 medições se comporta como constante efetiva ao longo das 17.744 instâncias. **Atributos com alta taxa de valores ausentes.** A inspeção da proporção de NaN por atributo identificou **um único atributo** com taxa superior a 5%: `nonlin_sampen_rr`, que apresentou **100% de valores ausentes**. Esse resultado era esperado e documentado no Entregável 6: a entropia amostral sobre a série RR requer no mínimo 8 batimentos detectados para um cálculo numericamente estável, condição não satisfeita por nenhum dos 17.744 registros — todos com menos de 15 batimentos em 10 s a frequências fisiológicas normais. O atributo foi removido, reduzindo o conjunto para 230 atributos com dados completos ou com taxa de ausência inferior a 5%. **Imputação por mediana estratificada.** O conjunto de atributos com ausência residual (taxa < 5%) compreende as métricas do diagrama de Poincaré (`nonlin_sd1`, `nonlin_sd2`, `nonlin_sd1_sd2_ratio`), com $\approx 2,7\%$ de NaN, e algumas métricas de HRV e morfologia do segmento ST com proporção inferior a 0,03%. Os valores ausentes foram imputados pela mediana da superclasse primária correspondente, calculada exclusivamente sobre os registros dos folds de treino (1–8). **Razões espectrais (24 atributos).** Para cada uma das 12 derivações, foram calculadas duas razões adimensionais: a razão QRS/PT, definida como a potência na banda 5–25 Hz dividida pela potência na banda 0,5–5 Hz; e a razão QRS/Total, definida como a potência na banda 5–25 Hz dividida pela potência total (0,5–40 Hz). Um termo de regularização de 10^{-10} é somado ao denominador para evitar instabilidade numérica em registros com energia próxima de zero nas bandas de referência. Essas 24 *features* são invariantes à amplitude absoluta do sinal, tornando-as mais robustas que as potências absolutas para comparação interindividual: dois pacientes com morfologia de ECG idêntica mas amplitudes diferentes — decorrentes de variações de impedância ou biotipo — produzirão as mesmas razões. **Normalização por baseline NORM (24 atributos).** Para as *features* de amplitude de primeira ordem — RMS e MAV em cada uma das 12 derivações —, foi calculada a mediana do grupo NORM nos registros de treino. Cada atributo foi então expresso como múltiplo dessa mediana, gerando 24 *features* interpretáveis diretamente como “fator de amplitude relativo ao padrão normal”. Um registro com `norm_baseline_rms_V5` = 1,8 apresenta amplitude RMS em V5 equivalente a 1,8 vezes a mediana de pacientes normais no conjunto de treino — desvio consistente com hipertrofia ventricular esquerda, por exemplo.

Os valores de referência foram calculados exclusivamente sobre os 14.035 registros NORM dos folds 1–8, sem acesso à distribuição de validação ou teste. Foram calculados quatro deltas de amplitude baseados na amplitude R mediana (ou, quando esta não estava disponível, no RMS da derivação) entre os pares: DI–aVR (eixo horizontal, eletricamente oposto), DII–aVL (eixo oblíquo inferior-lateral), V1–V6 e V2–V5 (gradientes transversais septo-lateral). Um quinto atributo derivado (delta_wavelet_D3_D4) captura a diferença de energia entre as sub-bandas D_3 (12,5–25 Hz, pico do QRS) e D_4 (6,25–12,5 Hz, início do QRS) da derivação DII, quantificando a concentração de energia dentro do complexo QRS: valores positivos elevados caracterizam QRS estreito e bem definido (padrão normal e HYP), enquanto valores próximos de zero indicam redistribuição de energia entre as duas faixas, compatível com bloqueios de ramo. A Tabela 10 apresenta um resumo das categorias de *features* derivadas adicionadas, com contagem e exemplos representativos. Ao final desta etapa, o dataset conta com $230 + 53 = 283$

Tabela 10 – Resumo das features de segunda ordem construídas no Entregável 7

Categoria	Nº	Prefixo	Justificativa
	24	ratio_	Invariante à amplitude; sensível a redistribuição espectral
Razões espectrais (QRS/PT e QRS/Total $\times$ 12 derivações)			
Normalização por baseline NORM (RMS e MAV $\times$ 12 derivações)	24	norm_baseline_	Grau de desvio relativo ao padrão fisiológico normal
Deltas morfológicos inter-derivações e wavelet	5	delta_	Gradientes elétricos entre regiões cardíacas complementares
	53	—	—
Total de features derivadas			

Fonte: elaborado pelos autores.

atributos.

Normalização Robusta


O RobustScaler foi fitado sobre os 14.241 registros dos folds de treino (1–8) e aplicado, sem reajuste, a todo o dataset. Para cada atributo, o escalonador calcula a mediana Q_{50} e o intervalo interquartil $IQR = Q_{75} - Q_{25}$ sobre o conjunto de treino, centralizando e escalonando os dados conforme a Equação 2.7. A verificação estatística pós-escalonamento sobre o conjunto de treino confirmou o comportamento esperado: a média das medianas das *features* escaladas ficou em $\approx 0,0$ (dentro de tolerância numérica de 10^{-10}) e a média dos IQRs ficou em $\approx 1,0$. Nenhum atributo apresentou IQR fora do intervalo $[0,8; 1,2]$, indicando consistência plena do

escalamento. A Figura ?? ilustra as distribuições de seis atributos representativos — um por domínio — antes e depois do escalamento no conjunto de treino. Em todos os casos, o RobustScaler centraliza a distribuição em torno de zero e comprime a escala, sem alterar a forma subjacente da distribuição.

Validação de Relevância — ANOVA *F*-Statistic

O ranking ANOVA *one-vs-rest* foi calculado sobre o conjunto de treino para cada uma das cinco superclasses. Os resultados revelam uma hierarquia biologicamente coerente.

Figura 6 – Top 30 *features* por *F*-statistic máxima (ANOVA *one-vs-rest*, conjunto de treino), coloridas pela superclasse dominante



Fonte: elaborado pelos autores.

A presença de *features* derivadas do E7 no Top 30 — incluindo `norm_baseline_rms_III` e `delta_amp_II_aVL` com *F*-statistics expressivas — confirma que as transformações de segunda ordem ampliam a separabilidade além do que as *features* brutas individualmente proporcionam. A distribuição por superclasse dominante no Top 30 evidencia que cada classe possui seu conjunto característico de atributos mais discriminativos: CD concentra-se em domínios de morfologia temporal (assimetria, largura do QRS); HYP, em domínios de energia e amplitude; STTC e MI, em atributos morfológicos de repolarização.

Análise de Redundância

A matriz de correlação de Pearson foi calculada sobre o subconjunto das 50 *features* com maior $F_{\max}$ no conjunto de treino. A Figura ?? apresenta o *heatmap* resultante, revelando uma estrutura clara de blocos correlacionados dentro de domínios fisiológicos. A análise identifica dois tipos distintos de redundância. O primeiro é de natureza **matemática direta**: os pares `time_rms_*` $\leftrightarrow$ `norm_baseline_rms_*` apresentam $|r| = 1,0$ exato, pois a normalização por *baseline* é uma transformação linear determinística (divisão por uma constante do treino); e o par `hrv_rmssd` $\leftrightarrow$ `nonlin_sd1` apresenta correlação unitária porque SD1 é, por definição matemática, proporcional ao RMSSD ($SD1 = RMSSD/\sqrt{2}$). Analogamente, SDNN e SD2 do diagrama de Poincaré capturam componentes sobrepostas da variabilidade de longo prazo, resultando em alta correlação mesmo não sendo matematicamente equivalentes.

Validação Final e Separabilidade por Classe

A Figura ?? apresenta os *boxplots* de seis atributos-chave — um por domínio — estratificados por superclasse diagnóstica, no espaço normalizado pelo RobustScaler. A análise visual por atributo é coerente com os resultados do ranking ANOVA. O atributo `morph_t_amp_V5_median` mostra separação relevante para HYP e STTC: HYP apresenta a mediana mais negativa e o maior IQR, indicando grande variabilidade na repolarização ventricular; NORM é a única classe com mediana consistentemente positiva. Por fim, o `wavelet_energy_D3_V5` reforça o padrão espectral, com HYP bem separada das demais por concentração de energia na faixa do pico do QRS. Esse padrão sustenta e dimensiona as escolhas metodológicas das etapas seguintes: o E8 aplicará PCA para comprimir o espaço e capturar interações entre atributos; o E9 realizará seleção formal priorizando atributos de diferentes domínios para garantir cobertura multivariada.

Saídas e Conexão com os Entregáveis 8 e 9

Os artefatos produzidos por esta etapa são: `features_engineered.parquet` (17.744 instâncias $\times$ 283 atributos, dataset completo normalizado); `features_engineered_sample.csv` (primeiras 500 linhas para inspeção rápida); `feature_catalog_e7.csv` (catálogo com domínio, $F_{\max}$, classe discriminada e estatísticas do treino por atributo); e `scaler_robust.pkl` (parâmetros do `RobustScaler` para reaplicação reproduzível). O arquivo `features_engineered.parquet` constitui a entrada comum dos Entregáveis 8 e 9, que percorrem trilhas paralelas e complementares: compressão via PCA (E8) e seleção de atributos originais interpretáveis (E9).

4.8 Entregável 8 — Redução de Dimensionalidade

Esta etapa aplica técnicas de redução de dimensionalidade sobre o dataset produzido pelo Entregável 7 (`features_engineered.parquet`, 17.744 instâncias $\times$ 283 atributos), com dois objetivos complementares: comprimir o vetor de *features* para reduzir o custo computacional dos classificadores e eliminar redundâncias estruturais; e analisar a estrutura latente do espaço de atributos, verificando se as superclasses diagnósticas formam agrupamentos coerentes antes da classificação formal. O primeiro é a razão entre o número de *features* e o limiar heurístico $\sqrt{N}$, onde N é o número de registros:

$$\frac{F}{\sqrt{N}} = \frac{283}{\sqrt{17744}} \approx 2,12 \quad (4.2)$$

O valor $> 1,0$ sinaliza que a redução de dimensionalidade é altamente recomendada: o espaço de *features* é mais que o dobro do limiar a partir do qual algoritmos baseados em distância começam a perder discriminabilidade.

Padronização e PCA Completo

O `StandardScaler` foi ajustado exclusivamente sobre os folds de treino, produzindo *features* com média zero e variância unitária por coluna — condição necessária para que o PCA não seja dominado por atributos de maior magnitude. A distribuição de variância explicada, apresentada na Figura ??, revela um padrão de concentração progressiva: o PC1 captura aproximadamente 22,1% da variância total, seguido de PC2 ($\approx 11,5\%$), PC3 ($\approx 6,8\%$) e PC4 ($\approx 5,2\%$), com queda gradual nos componentes subsequentes. O *Scree Plot* apresenta um cotovelo situado entre $K \approx 10$ e $K \approx 20$, indicando que até esse intervalo a redução de variância


por componente ainda é expressiva.

A Tabela ?? apresenta os resultados dos critérios de seleção de K avaliados. A divergência entre o critério de Kaiser (37 componentes) e o de 95% de variância acumulada (79 componentes) evidencia a presença de uma **cauda longa de variância difusa**: há um conjunto numeroso de componentes com contribuição individual modesta, mas que coletivamente representam uma fração não desprezível da variância total. Para definir K de forma objetiva, os três candidatos principais foram comparados pelo RMSE de reconstrução no espaço padronizado: $K = 20$ resultou em $\text{RMSE} = 0,4677$; $K = 37$, em $\text{RMSE} = 0,3716$; e $K = 79$, em $\text{RMSE} = 0,2227$.

Interpretação Fisiológica dos Loadings

O *heatmap* de *loadings* dos dez primeiros PCs, apresentado na Figura 7, permite associar cada componente a aspectos específicos da fisiologia cardíaca. O **PC1** é dominado por

Figura 7 – *Heatmap* de *loadings* dos 10 primeiros componentes principais sobre as Top 40 *features* de maior contribuição



Fonte: elaborado pelos autores.

features de amplitude global — `time_mav_*` e suas versões normalizadas (`norm_baseline_*`) em múltiplas derivações, todas com sinal positivo e magnitudes próximas.

Projeção 2D com Elipses de Confiança

A Figura ?? apresenta a projeção das superclasses nos planos PC1–PC2, PC1–PC3 e PC2–PC3, com elipses de confiança de 1σ construídas a partir da matriz de covariância bidimensional de cada classe. Os três planos revelam sobreposição expressiva entre as classes, confirmando que o problema não é linearmente separável em baixa dimensão.

Modelo PCA Final e Validação por Reconstrução

O modelo PCA final com $K = 79$ componentes foi fitado no conjunto de treino e aplicado a todo o dataset, produzindo a representação comprimida com 72,1% de compressão e variância retida de 95,00%. A Figura ?? apresenta os *boxplots* de RMSE de reconstrução por superclasse, e a Tabela ?? apresenta o RMSE médio por conjunto. O RMSE global de $\approx 0,21$ indica que, em média, cada *feature* é reconstruída com erro de 0,21 desvios padrão — valor adequado para uma compressão de 72%. A variação entre classes é moderada: **CD** apresenta o maior erro médio ($\approx 0,24$), coerente com a maior heterogeneidade morfológica dos distúrbios de condução; **NORM** apresenta o menor ($\approx 0,17$), reflexo da maior homogeneidade dos sinais normais.

FastICA sobre os Componentes PCA

O FastICA foi aplicado sobre os primeiros 20 componentes PCA (`n_components = min(20, 79)`) ajustado exclusivamente no conjunto de treino e aplicado a todo o dataset. O algoritmo convergiu em número de iterações bem inferior ao limite máximo de 1.000, indicando boa separabilidade das fontes no espaço PCA reduzido. A Tabela 11 apresenta os cinco ICs menos informativos, candidatos a descarte em etapas futuras. O padrão de candidatos a descarte é coerente com a

Tabela 11 – Componentes independentes candidatos a descarte (menor F -score combinado com menor curtose)

Componente	F -score (ANOVA)	Curtose	Interpretação
IC20	Baixo	Baixa ($\approx$ gaussiana)	Varição residual sem estrutura discriminativa
IC13	Baixo	Baixa	Idem
IC6	Baixo	Baixa	Idem
IC5	Moderado	Baixa	Discriminativo mas aproximadamente gaussiano
IC8	Baixo	Alta	Estrutura independente sem relevância diagnóstica

Fonte: elaborado pelos autores.

teoria: IC20, IC13 e IC6 combinam baixo F -score e baixa curtose, caracterizando componentes próximos de ruído estruturalmente gaussiano sem capacidade discriminativa. IC5 apresenta F -score moderado com distribuição quase gaussiana, enquanto IC8 exibe alta curtose — indicando presença de eventos raros ou distribuição de caudas pesadas — mas sem poder discriminativo entre as superclasses.

Saídas e Conexão com os Entregáveis 9 e RP

Os artefatos produzidos são: `features_pca.parquet` (17.744 instâncias $\times$ 87 colunas: 8 de metadados + 79 PCs); `pca_pipeline.pkl` (pipeline completo com `StandardScaler`, modelo PCA, modelo ICA e decisões analíticas serializadas); e `pca_variancia_componentes.csv` (variância explicada e acumulada por componente para documentação).

4.9 Entregável 9 — Seleção de Atributos

Esta etapa realiza a seleção formal do subconjunto de features originais com maior poder discriminativo para o problema de classificação das superclasses do PTB-XL, operando sobre o dataset engenheirado produzido no Entregável 7 (`features_engineered.parquet`). A entrada possui 17.744 registros e 282 features; a saída é um subconjunto de 30 atributos interpretáveis, acompanhados de validação estatística formal e do pipeline serializado para aplicação em novos dados.

Motivação e Contexto

Com 282 features distribuídas em cinco domínios (temporal, espectral, morfológico/HRV, tempo-frequência e não-linear), o espaço de representação construído nos Entregáveis 6 e 7 é consideravelmente superdimensionado. A razão $F/\sqrt{N} \approx 2,12$, calculada no E8, confirma que o problema se enquadra na chamada *curse of dimensionality*: algoritmos baseados em distância perdem discriminabilidade à medida que o espaço cresce.

Filter Methods — Avaliação Univariada


Três métodos de filtro foram aplicados sobre o conjunto de treino (folds 1–8, 14.241 registros após a remoção dos registros sem classe primária definida). O **ANOVA F-score** (função `f_classif`, `scikit-learn`) foi calculado para todas as 282 features, com a hipótese nula de que as médias são iguais entre as cinco superclasses. Todas as features apresentaram $p < 0,05$, e a totalidade exibiu p -valores inferiores a 10^{-10} — indicando que, ao nível de significância estatística, a separabilidade linear é generalizada por todo o espaço de atributos. O ranking resultante foi liderado por `morph_t_amp_V5_median` ($I = 0,2326$) e `morph_t_amp_II_median` ($I = 0,1924$), seguidos de `time_skew_II` ($I = 0,1541$) e `norm_baseline_rms_III` ($I = 0,1508$). O **ReliefF**

(amostra de 5.000 instâncias, $k = 10$ vizinhos, implementação skrebate) produziu um ranking com ênfase diferente: `morph_r_amp_II_median` liderou com score 0,04526, seguida de `delta_amp_II_aVL` (0,04076) e `morph_r_amp_V5_median` (0,03521). A Figura ?? apresenta o *heatmap* de rankings normalizados das 50 features mais bem posicionadas no ranking agregado, evidenciando a consistência entre os três critérios.

Wrapper Methods — Avaliação por Desempenho em Validação Cruzada

Os métodos wrapper foram aplicados sobre o *top-50* do ranking de filtros, operando com regressão logística L2 (LogisticRegression, $C = 1,0$, solver lbfgs) em validação cruzada estratificada de 5 *folds*. O algoritmo convergiu para um subconjunto de 20 features (`n_features_to_select = 20`). O **Sequential Backward Elimination (SBE)** partiu do conjunto completo de 50 candidatas e removeu iterativamente a feature menos indispensável até atingir 20 features. O valor ótimo encontrado foi $C = 0,1$ ($\lambda = 10$), indicando regularização relativamente forte. O **Random Forest** (300 árvores, `max_depth = 15`, `min_samples_leaf = 5`, `class_weight = 'balanced'`) produziu um ranking de importância Gini com curva de acumulação gradual: aproximadamente 221 features foram necessárias para acumular 90% da importância total, confirmando a distribuição difusa de relevância observada pelo LASSO.

Figura 8 – Top-30 features por importância Gini (Random Forest) e curva de importância acumulada com marcação dos limiares de 50, 75, 90 e 99%



Fonte: elaborado pelos autores.

Validação Estatística por Feature

A validação estatística foi conduzida sobre o conjunto de candidatas reunido pela união dos métodos anteriores: *top-80* filtros, subconjunto SFS, subconjunto SBE, *top-60* LASSO e *top-60* RF, resultando em 127 features candidatas únicas. O **teste de Kruskal-Wallis** (extensão não-paramétrica da ANOVA para $C > 2$ classes) foi aplicado a cada uma das 127 candidatas, testando a hipótese nula de que as distribuições são idênticas entre as cinco superclasses. Todas as 127 features apresentaram $p < 0,001$, com a grande maioria exibindo $p \ll 10^{-50}$, indicando diferenças altamente significativas entre classes em todo o espaço candidato. A **correção de Bonferroni** e a **correção FDR-BH** (BENJAMINI; HOCHBERG, 1995) foram aplicadas sobre os $M = 127$ p -valores resultantes. Tanto sob Bonferroni (controle do FWER) quanto sob FDR-BH (controle da taxa de falsas descobertas a 5%), todas as 127 features permaneceram significativas — resultado esperado dado o tamanho amostral e a magnitude das estatísticas H observadas. O **eta-quadrado** (η^2) foi calculado para cada feature como medida de effect size, interpretável como a proporção da variância total explicada pela classe:

$$\eta^2 = \frac{H - k + 1}{N - k} \quad (4.3)$$

onde H é a estatística de Kruskal-Wallis, k é o número de grupos e N é o número total de observações. Seguindo os limiares de Cohen (COHEN, 1988), os valores foram classificados em: pequeno ($\eta^2 < 0,01$), médio ($0,01 \leq \eta^2 < 0,14$) e grande ($\eta^2 \geq 0,14$). A Figura ?? apresenta a distribuição dos p -values brutos e a comparação entre os critérios de significância.

Consolidação por Borda Count Ponderado e Seleção Final

O ranking final foi construído pela agregação ponderada dos métodos aplicados, com pesos diferenciados conforme a capacidade de cada abordagem em capturar interações e não-linearidades. Métodos embedded e wrapper receberam peso 2,0; filtros não-lineares (MI, ReliefF) e effect size, peso 1,5; e ANOVA F-score, peso 1,0, conforme descrito na Seção 2.8.4. As 30 features com maior score agregado foram selecionadas como subconjunto final, todas satisfazendo simultaneamente os critérios de $\text{FDR-BH} < 0,05$ e η^2 na faixa de efeito médio ou grande. A Tabela ?? apresenta a composição do subconjunto final por domínio. As features temporais dominaram o subconjunto final (13 das 30), com destaque para métricas de assimetria (`time_skew_*`), curtose (`time_kurt_*`), variância (`time_var_*`) e amplitude média (`time_mav_*`). Um aspecto metodológico relevante é que 19 das 30 features finais exibem efeito

classificado como grande ($\eta^2 \geq 0,14$) e as 11 restantes apresentam efeito médio. Nenhuma feature com efeito pequeno foi incluída no subconjunto final, garantindo que o critério de seleção preserve tanto a significância estatística quanto a relevância prática para a separação entre as superclasses cardíacas.

A Figura ?? apresenta os *boxplots* das distribuições por classe das 12 features mais bem posicionadas no ranking final, confirmando visualmente a separabilidade expressiva entre os grupos e a coerência fisiológica dos padrões observados.


Saídas e Conexão com o Entregável 10 e o Módulo de RP

Três artefatos foram produzidos: `features_selected.parquet` (17.744 instâncias $\times$ 30 features selecionadas + colunas de metadados), que constitui a representação interpretável para os classificadores de Reconhecimento de Padrões; `features_selected_ranking.csv`, com a tabela completa de ranking, scores e effect sizes das 127 candidatas avaliadas; e `feature_selection_pipeline.pkl`, que serializa o *scaler*, a lista de features originais, o subconjunto selecionado e os metadados do processo de seleção, permitindo aplicação direta em dados novos sem necessidade de reprocessamento. A redução obtida foi de 89,4% em relação às 282 features do E7, passando de um espaço com potencial de multicolinearidade e redundância para um subconjunto compacto onde cada atributo possui identidade fisiológica clara.

4.10 Entregável 10 — Validação Estatística Final do Dataset

Esta etapa constitui a verificação formal de adequação do dataset antes de sua entrega ao módulo de Reconhecimento de Padrões. O dataset de entrada é o subconjunto de 30 features produzido pelo Entregável 9 (`features_selected.parquet`), compreendendo 17.744 registros divididos em treino (14.241), validação (1.756) e teste (1.747). O cálculo inicial sobre as 30 features selecionadas revelou colinearidade severa em 15 delas e a presença de valores infinitos em quatro — indicativo de dependência linear exata: `norm_baseline_mav_III` e `time_mav_III`, bem como `norm_baseline_rms_V6` e `time_rms_V6`. Nove features foram removidas ao longo de nove iterações, conforme o histórico apresentado na Tabela ?. Após as nove remoções, o conjunto final conta com 21 features. O VIF máximo residual caiu para 6,24 (`time_skew_II`), a média passou para 3,23 e nenhuma feature ultrapassou o limiar de severidade. É importante registrar que as features removidas pelo VIF não são necessariamente

Figura 9 – *Heatmap* de correlação residual entre as 21 features após remoção iterativa por VIF (limiar = 10), calculado sobre o conjunto de treino



irrelevantes para o problema — muitas delas estavam entre as mais bem posicionadas no ranking do E9.

Separabilidade Estatística das Classes

Com as 21 features finais definidas, a separabilidade das cinco superclasses foi avaliada em três níveis: global (Kruskal-Wallis), par-a-par (Mann-Whitney U) e visual (projeção LDA 2D). **Kruskal-Wallis por feature.** O teste não paramétrico de Kruskal-Wallis foi aplicado a cada uma das 21 features sobre o conjunto de treino, testando a hipótese nula de distribuições idênticas entre as seis categorias diagnósticas (NORM, MI, STTC, CD, HYP, NONE). Todas as 21 features apresentaram rejeição da hipótese nula com $p < 10^{-50}$ antes e após correção FDR-

BH (BENJAMINI; HOCHBERG, 1995) — resultado que confirma a robustez da separabilidade frente ao problema de múltiplas comparações. A estatística H de Kruskal-Wallis mediana sobre as 21 features foi elevada, com o topo do ranking dominado por features morfológicas e de assimetria temporal, conforme detalhado na Tabela ???. O eta-quadrado (η^2), calculado segundo a Equação 4.3, classificou 13 das 21 features com efeito grande ($\eta^2 \geq 0,14$) e as 8 restantes com efeito médio ($0,01 \leq \eta^2 < 0,14$). **Mann-Whitney U — comparações par-a-par.** Para cada um dos 15 pares possíveis entre as seis categorias, o teste de Mann-Whitney U foi aplicado sobre cada uma das 21 features, com correção FDR-BH sobre o conjunto completo de $21 \times 15 = 315$ comparações. A Tabela 12 resume o número de features com separação significativa ($p_{\text{FDR}} < 0,05$) por par. Sete dos 15 pares apresentaram separação total (21/21

Tabela 12 – Número de features com separação estatisticamente significativa (Mann-Whitney U, $p_{\text{FDR}} < 0,05$) por par de superclasses

Par de classes	Features significativas (de 21)
CD vs HYP	21
CD vs MI	21
CD vs NORM	21
HYP vs NONE	21
MI vs NONE	21
MI vs STTC	21
HYP vs STTC	21
NONE vs STTC	20
CD vs STTC	20
CD vs NONE	20
MI vs NORM	20
HYP vs NORM	19
HYP vs MI	17
NONE vs NORM	17
NORM vs STTC	17

Fonte: elaborado pelos autores.

features), o que indica que praticamente todo o espaço de atributos distingue esses grupos. Os pares com menor separabilidade — HYP vs MI (17/21), NONE vs NORM (17/21) e NORM vs STTC (17/21) — refletem sobreposição fisiológica real: a hipertrofia ventricular e o infarto compartilham alterações de morfologia do QRS e de voltagem; registros sem classe primária definida (NONE) tendem a apresentar sinais próximos do padrão normal por não enquadramento nos critérios SCP-ECG de nenhuma superclasse; e as alterações de segmento ST/T (STTC) em sua expressão leve podem ser indistinguíveis de variações da normalidade em algumas derivações isoladas. **Projeção LDA 2D.** A Análise Discriminante Linear foi utilizada como ferramenta exclusiva de visualização, projetando o espaço de 21 features em dois eixos discriminantes

que maximizam a separação entre as seis categorias (FISHER, 1936). A projeção resultante, apresentada na Figura ??, confirma que o espaço de atributos possui estrutura discriminativa real, com clusters distinguíveis para NORM, CD e MI no primeiro eixo discriminante. A sobreposição observada entre algumas classes, particularmente HYP vs MI e NONE vs NORM no plano 2D, é consistente com os resultados dos testes par-a-par e reflete que a separabilidade plena dessas classes emerge da combinação de múltiplas features — não de projeções bidimensionais.

Avaliação de Balanceamento das Classes

A distribuição de classes no dataset foi quantificada por dois indicadores complementares: o **Imbalance Ratio** (IR), definido como a razão entre o número de instâncias da classe majoritária e da minoritária, e a **entropia de Shannon normalizada** (H_{norm}), que mede quão uniformemente as instâncias estão distribuídas entre as classes ($H_{\text{norm}} = 1$ para distribuição perfeitamente uniforme; $H_{\text{norm}} = 0$ para concentração total em uma única classe). A Tabela ?? apresenta a distribuição por split e os indicadores de desbalanceamento calculados.

O IR de 21,88 (treino e teste) e 35,85 (validação) evidencia desbalanceamento severo, concentrado principalmente na classe NONE, que representa apenas 1,85% do conjunto de treino com 264 registros — registros em que nenhuma das cinco superclasses diagnósticas alcançou o limiar de *likelihood* $\geq 50\%$ estabelecido pelo PTB-XL. A entropia normalizada de $H_{\text{norm}} \approx 0,85$ confirma que, excluída a classe NONE, a distribuição entre as demais classes é moderadamente heterogênea mas longe do desequilíbrio extremo. Primeiro, a **proporção por split é estável**: as porcentagens entre treino, validação e teste são consistentes para todas as classes, reflexo da estratificação nativa do PTB-XL por folds. A dimensão multi-label não foi explicitamente tratada nesta validação, pois as análises são conduzidas sobre a classe primária para compatibilidade com avaliações supervisionadas clássicas. Três abordagens são recomendadas em complementaridade: (i) **ponderação de classes** (`class_weight = 'balanced'`), disponível nativamente em regressão logística, SVM e Random Forest do `scikit-learn`, que atribui pesos inversamente proporcionais à frequência de classe durante o treinamento; (ii) **reamostragem sintética** via SMOTE (*Synthetic Minority Oversampling Technique*), que gera instâncias artificiais da classe minoritária por interpolação no espaço de features; e (iii) **métricas de avaliação adequadas** — acurácia global é uma métrica enganosa neste contexto; F1-score macro, AUC-ROC por classe e matriz de confusão normalizada são as métricas primárias recomendadas, pois tratam todas as classes com peso equivalente independentemente do seu volume.

Curvas de Densidade por Classe e Coeficiente de Bhattacharyya

As curvas de densidade KDE (*Kernel Density Estimation*) por classe revelam a estrutura das distribuições de cada feature em nível univariado. A Figura ?? apresenta as estimativas para as seis features com maior η^2 , com sobreposição por superclasse.

A sobreposição entre distribuições foi quantificada pelo **coeficiente de Bhattacharyya** (BC) (BHATTACHARYYA, 1943), calculado numericamente a partir das estimativas KDE:

$$BC(p, q) = \int \sqrt{p(x)q(x)} dx \quad (4.4)$$

onde p e q são as densidades estimadas das duas classes comparadas. $BC = 0$ indica distribuições completamente separadas (separação perfeita); $BC = 1$ indica distribuições idênticas (sobreposição total). Features morfológicas do complexo QRS (`morph_qrs_width_ms_V5_median`, `morph_t_amp_V5_median`) e de assimetria temporal (`time_skew_II`, `time_skew_V1`) apresentam, em média, menores valores de BC em múltiplos pares de classes, confirmando sua posição de destaque no ranking de η^2 . Primeiro, pares que envolvem CD apresentam boa separabilidade nas features de assimetria (`time_skew_aVL`, `time_kurt_aVL`) mas elevada sobreposição nas features espectrais de banda PT, o que é fisiopatologicamente coerente: distúrbios de condução intraventricular modificam primariamente a forma e a duração do QRS, e não necessariamente a potência nas bandas de baixa frequência.

Tabela Final de Atributos

A Tabela ?? consolida o catálogo completo das 21 features do dataset final, com domínio de origem, estatísticas descritivas no treino, posição no ranking por η^2 e VIF pós-remoção. Esta tabela constitui o documento de referência para o módulo de RP e para a interpretação clínica dos resultados da classificação. A composição por domínio do conjunto final reflete uma concentração em features temporais (9 features: `time_skew_II`, `time_kurt_V1`, `time_skew_V6`, `time_skew_V1`, `time_skew_aVF`, `time_kurt_aVL`, `time_p2p_III`, `time_skew_V4` e `time_var_V6`) e morfológicas (4 features) — domínios que capturam diretamente as alterações de forma e de distribuição de amplitudes associadas às patologias cardíacas. Features de frequência (4 features: `freq_pt_power_III`, `freq_qrs_power_III`, `freq_qrs_power_aVL` e `freq_centroid_I`) e domínios derivados (`delta_amp_II_aVL`, `norm_baseline_mav_aVL`, `ratio_qrs_total_V1`

e `wavelet_energy_D1_II`) compõem o restante, com efeitos predominantemente médios a grandes.

Saídas e Conexão com o Módulo de Reconhecimento de Padrões

Seis artefatos foram produzidos por este entregável: `dataset_final_validado.parquet` (17.744 instâncias $\times$ 28 colunas — 21 features + 7 colunas de metadados), que é o arquivo de entrada definitivo para o módulo de RP; `dataset_final_validado_sample.csv` (primeiras 500 linhas, para inspeção rápida); `feature_catalog_e10.csv` (catálogo completo com nome, domínio, estatísticas descritivas, η^2 , ranking e VIF); `relatorio_vif.csv`; `relatorio_kruskal_wallis.csv`; e `relatorio_balanceamento.csv`. O dataset final satisfaz simultaneamente quatro propriedades: ausência de valores nulos (0 NaN em todas as 21 features); ausência de multicolinearidade severa (VIF máximo de 6,24); separabilidade estatística formal de todas as 21 features em escala de efeito médio a grande; e desbalanceamento devidamente documentado com estratégias compensatórias indicadas. As representações `dataset_final_validado.parquet` (trilha interpretável, 21 features originais) e `features_pca.parquet` (trilha comprimida, 79 componentes principais) constituem os dois pontos de entrada alternativos para o módulo de Reconhecimento de Padrões, possibilitando a comparação sistemática entre abordagens de classificação baseadas em features originais e em componentes latentes.

5 CONCLUSÕES E TRABALHOS FUTUROS

5.1 Síntese dos Resultados

Este trabalho apresentou o desenvolvimento e a validação de um pipeline completo de aquisição e preparação de biossinais de ECG para RP, estruturado em dez etapas sequenciais que percorrem o caminho dos sinais brutos do PTB-XL até a entrega de um dataset estatisticamente validado e pronto para classificação.

O ponto de partida foi o **Entregável 1**, que inspecionou os 21.799 registros de ECG de 18.869 pacientes do PTB-XL, verificando a integridade da partição treino/validação/teste e confirmando a ausência de vazamento de dados em nível de paciente. A análise demográfica revelou mediana de idade próxima a 62 anos, ligeira predominância do sexo masculino ($\approx 55\%$) e desbalanceamento diagnóstico esperado, com NORM e MI como as superclasses mais frequentes e HYP como a menos representada.

O **Entregável 2** quantificou objetivamente a qualidade de todos os registros por meio de oito métricas SQI combinadas em um classificador heurístico em cascata (*Gatekeeper*). Com limiares otimizados empiricamente dentro de uma faixa de $\pm 10\%$ dos valores da literatura, o Gatekeeper classificou os registros em quatro categorias e identificou 1.959 registros inaceitáveis (U), que foram excluídos do pipeline a partir desta etapa.

O **Entregável 3** conduziu a análise estatística diagnóstica sobre os 19.840 registros restantes. A aplicação dos testes de Shapiro-Wilk, Kolmogorov-Smirnov, Levene e Bartlett demonstrou rejeição da normalidade para todas as variáveis analisadas e violação da homocedasticidade na grande maioria das métricas de sinal. Essa decisão metodológica — adoção de testes não paramétricos (Kruskal-Wallis, Mann-Whitney U, Wilcoxon e correlação de Spearman) em todos os entregáveis subsequentes — foi formalmente fundamentada e documentada nesta etapa.

O **Entregável 4** aplicou o pipeline de pré-processamento sobre os 19.840 registros G/A/P: filtragem Butterworth bidirecional (passa-alta 0,5 Hz e passa-baixa 40 Hz, ordem 5) e winsorização por percentis 0,5–99,5% por derivação, com parâmetros calculados exclusivamente nos folds de treino. A validação por Wilcoxon pareado confirmou redução estatisticamente significativa de energia em todos os grupos com artefato anotado ($p < 0,001$ em todos os casos). A reavaliação SQI pós-limpeza revelou redução expressiva da classe P (de $\approx 17\%$ para menos de 2%) e surgimento de registros G inexistentes na avaliação original. Os 17.744 registros reclassificados como G ou A foram retidos para as etapas seguintes.

O **Entregável 5** segmentou os 17.744 sinais limpos em dois níveis. No nível de registro, cada ECG de 10 s ($1.000 \text{ amostras} \times 12 \text{ derivações}$) constitui a instância principal do pipeline. No nível de batimento, o detector Pan-Tompkins identificou e extraiu 211.442 janelas de 600 ms centradas nos picos R, com média de 11,9 batimentos por registro — valor fisiologicamente consistente com a faixa de frequências cardíacas esperada. O teste de Kruskal-Wallis confirmou diferenças estatisticamente significativas nas métricas de variabilidade inter-janela entre superclasses ($p < 0,001$), validando o potencial discriminativo da segmentação.

O **Entregável 6** transformou os sinais segmentados em vetores de atributos distribuídos em cinco domínios: 84 features temporais, 84 features espectrais (Welch), features morfológicas e de HRV (extraídas por batimento e agregadas ao nível do registro), 32 features de tempo-frequência (DWT db4, 4 níveis) e 6 features não-lineares (Higuchi, DFA, SampEn, SD1, SD2 e razão SD1/SD2). O *sanity check* confirmou ausência de NaN nos domínios de sinal (tempo, frequência e wavelet) e concentração de valores ausentes ($< 5\%$) nas métricas não-lineares da série RR.

O **Entregável 7** realizou a engenharia de features: remoção da `nonlin_sampen_rr` (NaN em 100% dos registros, por insuficiência de batimentos), imputação dos NaN residuais pela mediana da superclasse no treino, criação de 24 razões espectrais adimensionais, 24 features de normalização por *baseline* NORM e 5 deltas morfológicos entre derivações complementares, seguida de normalização robusta por `RobustScaler` fitado nos folds 1–8. A análise de redundância identificou pares de features matematicamente equivalentes (ex.: `time_rms_*` e `norm_baseline_rms_*`), formalmente tratados no Entregável 9.

O **Entregável 8** aplicou PCA sobre as 282 features do E7, após padronização por `StandardScaler`. O critério de variância acumulada $\geq 95\%$ selecionou $K = 79$ componentes principais, correspondendo a uma compressão de $\approx 72\%$ em relação ao espaço original. O RMSE de reconstrução ($\approx 0,21$ no espaço padronizado) foi estável entre treino, validação e teste, confirmando que a compressão não introduz viés. O FastICA aplicado sobre os 20 primeiros PCs permitiu identificar componentes independentes de menor relevância discriminativa, candidatos a descarte.

O **Entregável 9** selecionou formalmente as 30 features originais de maior poder discriminativo. Os métodos *filter* (ANOVA F-score, Informação Mútua e ReliefF), *wrapper* (SFS e SBE, com interseção de 11 features) e *embedded* (LASSO com $C = 0,1$ e Random Forest com 300 árvores) foram combinados via Borda Count ponderado. Todas as 127 features candidatas

mantidas após o pré-filtro de redundância foram estatisticamente significativas (Kruskal-Wallis com $\text{FDR-BH} < 0,05$), com 28 apresentando efeito grande ($\eta^2 \geq 0,14$) e 79, efeito médio. A redução final de 282 para 30 features representou uma compressão de 89,4%.

O **Entregável 10** validou o dataset de 30 features por análise de VIF iterativo, separabilidade estatística e balanceamento de classes. A remoção de 9 features com $\text{VIF} > 10$ — incluindo pares perfeitamente colineares como `norm_baseline_mav_III` e `time_mav_III` — resultou em um conjunto final de **21 features** sem multicolinearidade severa (VIF máximo residual de 6,24). Todas as 21 features apresentaram separabilidade estatística formal em escala de efeito médio a grande. O dataset `dataset_final_validado.parquet`, com 17.744 registros $\times$ 21 atributos, constitui o ponto de entrada para o módulo de RP.

5.2 Contribuições

As contribuições deste trabalho podem ser organizadas em três dimensões:

1. **Pipeline end-to-end documentado e reproduzível:** o conjunto de dez notebooks encadeados, com controle rigoroso de *data leakage* em todas as etapas e serialização dos parâmetros de pré-processamento (`preprocessing_params.pkl`, `scaler_robust.pkl`, `pca_pipeline.pkl` e `feature_selection_pipeline.pkl`), permite que qualquer pesquisador reproduza integralmente os resultados ou aplique o pipeline a novos dados;
2. **Classificador de qualidade de sinal (*Gatekeeper*):** a implementação do classificador heurístico em cascata com oito métricas SQI e limiares otimizados empiricamente constitui uma contribuição metodológica direta para pipelines de análise de ECG em dados heterogêneos de origem hospitalar, onde a variabilidade de qualidade é substancial;
3. **Espaço de atributos hierárquico e interpretável:** a extração de features em cinco domínios complementares, com agregação em dois níveis (registro e batimento), produz um conjunto de atributos que preserva a identidade fisiológica de cada variável — propriedade fundamental para a interpretação clínica dos resultados dos classificadores de RP;
4. **Dataset final validado:** o `dataset_final_validado.parquet` com 21 features de alta separabilidade, sem multicolinearidade severa, sem valores ausentes e com desbalanceamento documentado e estratégias compensatórias indicadas,

constitui um ponto de partida sólido para a aplicação de classificadores de RP sobre o PTB-XL.

5.3 Limitações

Algumas limitações devem ser consideradas na interpretação dos resultados e na aplicação do pipeline desenvolvido:

1. **Restrição ao ECG de repouso:** o PTB-XL contém exclusivamente registros de ECG de repouso de 10 s. O pipeline não foi avaliado sobre ECG de esforço (Holter) ou sobre registros de duração diferente, o que limita sua generalização direta a esses contextos;
2. **Taxa de amostragem de 100 Hz:** a versão de baixa resolução do PTB-XL adotada neste trabalho está adequada para a banda diagnóstica padrão (0,05–40 Hz), mas não captura componentes de alta frequência (> 50 Hz) relevantes para análises mais especializadas, como a variabilidade de alta frequência do QRS;
3. **Detector Pan-Tompkins em arritmias complexas:** o algoritmo de detecção de picos R pode falhar ou produzir detecções espúrias em cenários de fibrilação atrial de alta frequência ou bloqueios de alta ordem, comprometendo a qualidade das features morfológicas e de HRV calculadas a partir dos batimentos segmentados;
4. **Generalização a outros datasets:** o pipeline foi desenvolvido, calibrado e validado exclusivamente sobre o PTB-XL. A transferência direta para outros datasets de ECG — especialmente aqueles coletados com equipamentos diferentes ou em populações distintas — não é garantida sem re-calibração dos parâmetros de pré-processamento e dos limiares do Gatekeeper;
5. **Desbalanceamento de classes:** a distribuição desigual entre superclasses, com NORM muito mais representada que HYP, é um desafio reconhecido que não foi diretamente abordado neste pipeline de preparação de dados. A adoção de estratégias compensatórias (ponderação de classes, SMOTE ou subamostragem) é responsabilidade do módulo de RP.

5.4 Trabalhos Futuros

A continuidade natural deste trabalho é a aplicação de técnicas de RP sobre o dataset produzido. As duas representações entregues — `dataset_final_validado.parquet` (21 features interpretáveis, trilha de seleção de atributos) e `features_pca.parquet` (79 componentes principais, trilha de redução de dimensionalidade) — constituem os pontos de entrada para o treinamento e a avaliação comparativa de classificadores, como máquinas de vetores de suporte, florestas aleatórias e redes neurais, sobre as cinco superclasses diagnósticas do PTB-XL.

REFERÊNCIAS

- BARTLETT, M. S. Properties of sufficiency and statistical tests. **Proceedings of the Royal Society of London. Series A**, v. 160, n. 901, p. 268–282, 1937.
- BENJAMINI, Y.; HOCHBERG, Y. Controlling the false discovery rate: A practical and powerful approach to multiple testing. **Journal of the Royal Statistical Society: Series B**, v. 57, n. 1, p. 289–300, 1995.
- BHATTACHARYYA, A. K. On a measure of divergence between two statistical populations defined by their probability distributions. **Bulletin of the Calcutta Mathematical Society**, v. 35, p. 99–109, 1943.
- BISHOP, C. M. **Pattern Recognition and Machine Learning**. [S.l.]: Springer, 2006.
- BREIMAN, L. Random forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001.
- BROWN, M. B.; FORSYTHE, A. B. Robust tests for the equality of variances. **Journal of the American Statistical Association**, v. 69, n. 346, p. 364–367, 1974.
- COHEN, J. **Statistical Power Analysis for the Behavioral Sciences**. 2. ed. [S.l.]: Lawrence Erlbaum Associates, 1988.
- FISHER, R. A. **The Use of Multiple Measurements in Taxonomic Problems**. [S.l.: s.n.], 1936. v. 7. 179–188 p.
- GUSTAFSSON, F. Determining the initial states in forward-backward filtering. **IEEE Transactions on Signal Processing**, v. 44, n. 4, p. 988–992, 1996.
- GUYON, I.; ELISSEEFF, A. An introduction to variable and feature selection. **Journal of Machine Learning Research**, v. 3, p. 1157–1182, 2003.
- HIGUCHI, T. Approach to an irregular time series on the basis of the fractal theory. **Physica D: Nonlinear Phenomena**, v. 31, n. 2, p. 277–283, 1988.
- HYVÄRINEN, A.; OJA, E. Independent component analysis: Algorithms and applications. **Neural Networks**, v. 13, n. 4–5, p. 411–430, 2000.
- KLIGFIELD, P.; GETTES, L. S.; BAILEY, J. J.; CHILDERS, R.; DEAL, B. J.; HANCOCK, E. W.; HERPEN, G. van; KORS, J. A.; MACFARLANE, P.; MIRVIS, D. M.; PAHLM, O.; RAUTAHARJU, P.; WAGNER, G. S. Recommendations for the standardization and interpretation of the electrocardiogram: Part I: The electrocardiogram and its technology. **Journal of the American College of Cardiology**, v. 49, n. 10, p. 1109–1127, 2007.
- KONONENKO, I. Estimating attributes: Analysis and extensions of RELIEF. **Lecture Notes in Computer Science**, Springer, v. 784, p. 171–182, 1994.
- KRASKOV, A.; STÖGBAUER, H.; GRASSBERGER, P. Estimating mutual information. **Physical Review E**, v. 69, n. 6, p. 066138, 2004.
- KRUSKAL, W. H.; WALLIS, W. A. Use of ranks in one-criterion variance analysis. **Journal of the American Statistical Association**, v. 47, n. 260, p. 583–621, 1952.

- LEVENE, H. Robust tests for equality of variances. In: OLKIN, I. (Ed.). **Contributions to Probability and Statistics**. [S.l.]: Stanford University Press, 1960. p. 278–292.
- MALLAT, S. **A Wavelet Tour of Signal Processing**. 2. ed. [S.l.]: Academic Press, 1999.
- MANN, H. B.; WHITNEY, D. R. On a test of whether one of two random variables is stochastically larger than the other. **The Annals of Mathematical Statistics**, v. 18, n. 1, p. 50–60, 1947.
- MASSEY, F. J. The Kolmogorov-Smirnov test for goodness of fit. **Journal of the American Statistical Association**, v. 46, n. 253, p. 68–78, 1951.
- MONTGOMERY, D. C.; PECK, E. A.; VINING, G. G. **Introduction to Linear Regression Analysis**. 5. ed. Hoboken, NJ: Wiley, 2012.
- OPPENHEIM, A. V.; SCHAFER, R. W. **Discrete-Time Signal Processing**. 2. ed. [S.l.]: Prentice Hall, 1999.
- PAN, J.; TOMPKINS, W. J. A real-time QRS detection algorithm. **IEEE Transactions on Biomedical Engineering**, v. 32, n. 3, p. 230–236, 1985.
- PEDREGOSA, F.; VAROQUAUX, G.; GRAMFORT, A.; MICHEL, V.; THIRION, B.; GRISEL, O.; BLONDEL, M.; PRETTENHOFER, P.; WEISS, R.; DUBOURG, V.; VANDERPLAS, J.; PASSOS, A.; COUNAPEAU, D.; BRUCHER, M.; PERROT, M.; DUCHESNAY, É. Scikit-learn: Machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825–2830, 2011.
- RAZALI, N. M.; WAH, Y. B. Power comparisons of Shapiro-Wilk, Kolmogorov-Smirnov, Lilliefors and Anderson-Darling tests. **Journal of Statistical Modeling and Analytics**, v. 2, n. 1, p. 21–33, 2011.
- RICHMAN, J. S.; MOORMAN, J. R. Physiological time-series analysis using approximate entropy and sample entropy. **American Journal of Physiology — Heart and Circulatory Physiology**, v. 278, n. 6, p. H2039–H2049, 2000.
- SHAPIRO, S. S.; WILK, M. B. An analysis of variance test for normality (complete samples). **Biometrika**, v. 52, n. 3–4, p. 591–611, 1965.
- Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology. Heart rate variability: Standards of measurement, physiological interpretation, and clinical use. **Circulation**, v. 93, n. 5, p. 1043–1065, 1996.
- TIBSHIRANI, R. Regression shrinkage and selection via the lasso. **Journal of the Royal Statistical Society: Series B**, v. 58, n. 1, p. 267–288, 1996.
- TUKEY, J. W. **Exploratory Data Analysis**. [S.l.]: Addison-Wesley, 1977.
- WAGNER, P.; STRODTHOFF, N.; BOUSSELJOT, R.-D.; KREISELER, D.; LUNZE, F. I.; SAMEK, W.; SCHAEFFTER, T. PTB-XL, a large publicly available electrocardiography dataset. **Scientific Data**, v. 7, n. 1, p. 154, 2020.
- WHITNEY, A. W. A direct method of nonparametric measurement selection. **IEEE Transactions on Computers**, v. 20, n. 9, p. 1100–1103, 1971.

WILCOXON, F. Individual comparisons by ranking methods. **Biometrics Bulletin**, v. 1, n. 6, p. 80–83, 1945.

YOUNG, H. P. Condorcet's theory of voting. **American Political Science Review**, v. 82, n. 4, p. 1231–1244, 1988.