



UNIVERSIDADE FEDERAL DO CEARÁ
CENTRO DE TECNOLOGIA
DEPARTAMENTO DE ENGENHARIA DE TELEINFORMÁTICA
CURSO DE GRADUAÇÃO EM ENGENHARIA DE COMPUTAÇÃO

JOSÉ LESSA
MATHEUS ROCHA

**FERRAMENTA MNE-PYTHON, PANORAMA DE *SURVEYS* E SELEÇÃO DE BASE
DE DADOS**

FORTALEZA

2026

JOSÉ LESSA
MATHEUS ROCHA

FERRAMENTA MNE-PYTHON, PANORAMA DE *SURVEYS* E SELEÇÃO DE BASE DE
DADOS

1º Entregável apresentado como atividade avaliativa do Curso de Engenharia de Computação do Centro de Tecnologia da Universidade Federal do Ceará (UFC).

Orientador: Prof. Dr. Victor Hugo C. de Albuquerque

FORTALEZA

2026

RESUMO

A área de aquisição e análise de bio-sinais ocupa posição central no desenvolvimento de sistemas inteligentes de apoio ao diagnóstico clínico e ao monitoramento contínuo da saúde. Este trabalho apresenta três contribuições complementares que compõem a etapa introdutória do projeto da disciplina Aquisição dos Bio-sinais. A primeira é o estudo da ferramenta *Minimum Norm Estimate* / pacote MNE-Python (MNE), um dos principais pacotes de código aberto para análise de sinais eletrofisiológicos em Python, cujas estruturas de dados, capacidades de pré-processamento, visualização, análise espectral e decodificação são descritas em detalhe. A segunda contribuição é uma discussão das principais limitações da área de bio-sinais, fundamentada em dois *surveys* recentes: um dedicado à aplicação de Modelos de Linguagem de Grande Escala (LLMs) em bio-sinais e outro voltado para modelos de fundação para sinais biomédicos. Por fim, o trabalho apresenta a base de dados selecionada para o projeto — a Base de Dados de Eletrocardiografia PTB-XL (PTB-XL), disponível no repositório público de dados fisiológicos (PhysioNet) —, descrevendo sua origem, protocolo de aquisição, características técnicas e justificativa de escolha. O conjunto de dados é composto por 21.799 registros de Eletrocardiograma (ECG) de 12 derivações e 10 segundos de duração, provenientes de 18.869 pacientes, anotados por até dois cardiologistas em 71 classes diagnósticas, constituindo uma das maiores bases públicas de ECG disponíveis para pesquisa em classificação cardíaca.

Palavras-chave: Bio-sinais. ECG. MNE-Python. Modelos de fundação. Surveys. Base de dados. Classificação cardíaca.

ABSTRACT

The field of biosignal acquisition and analysis occupies a central position in the development of intelligent systems for clinical decision support and continuous health monitoring. This work presents three complementary contributions that form the introductory stage of the course project in Biosignal Acquisition. The first is a study of the MNE-Python tool, one of the leading open-source packages for electrophysiological signal analysis in Python, whose data structures, preprocessing capabilities, visualization, spectral analysis, and decoding features are described in detail. The second contribution is a discussion of the main limitations of the biosignal field, grounded in two recent surveys: one focused on the application of large language models (LLMs) to biosignals and another addressing foundation models for biomedical signals. Finally, the work presents the dataset selected for the course project — the PTB-XL database (PTB-XL), available on PhysioNet —, describing its origin, acquisition protocol, technical characteristics, and rationale for selection. The dataset comprises 21,799 clinical 12-lead ECG recordings of 10 seconds each from 18,869 patients, annotated by up to two cardiologists across 71 diagnostic classes, making it one of the largest publicly available ECG datasets for cardiac classification research.

Keywords: Biosignals. ECG. MNE-Python. Foundation models. Surveys. Dataset. Cardiac classification.

LISTA DE TABELAS

Tabela 1 – Resumo das quatro modalidades de biossinais abordadas pelo survey de Ding <i>et al.</i> (2024).	13
Tabela 2 – Síntese das principais limitações da área de biossinais identificadas nos <i>surveys</i>	16
Tabela 3 – Superclasses diagnósticas da PTB-XL e número aproximado de registros por categoria (WAGNER <i>et al.</i> , 2020).	17

LISTA DE ABREVIATURAS E SIGLAS

BCI	Interface Cérebro-Computador
BFMs	Modelos de Fundação para Biossinais
ECG	Eletrocardiograma
ECoG	Eletrocorticografia
EDF	<i>European Data Format</i>
EEG	Eletroencefalograma
EMG	Eletromiograma
ERP	Potencial Relacionado a Evento
FIR	Resposta ao Impulso Finita
fNIRS	Espectroscopia Funcional no Infravermelho Próximo
ICA	Análise de Componentes Independentes
IIR	Resposta ao Impulso Infinita
IMU	Unidade de Medição Inercial
LLMs	Modelos de Linguagem de Grande Escala
MEG	Magnetoencefalograma
MNE	<i>Minimum Norm Estimate</i> / pacote MNE-Python
NLP	Processamento de Linguagem Natural
PhysioNet	repositório público de dados fisiológicos
PPG	Fotopletismografia
PSD	Densidade Espectral de Potência
PTB-XL	Base de Dados de Eletrocardiografia PTB-XL
RP	Reconhecimento de Padrões
sEEG	EEG de Superfície Cortical Estéreo
SQI	Índice de Qualidade do Sinal

SUMÁRIO

1	INTRODUÇÃO	7
1.1	Organização do Documento	7
2	FERRAMENTA MNE-PYTHON	9
2.1	Pipeline de Análise e Estruturas de Dados	9
2.2	Pré-processamento	10
2.3	Visualização	10
2.4	Análise Espectral e Decodificação	10
3	PANORAMA DA ÁREA E LIMITAÇÕES IDENTIFICADAS	12
3.1	Contexto: Biossinais e Inteligência Artificial	12
3.2	Survey 1: LLMs em Aplicações de Biossinais	12
3.2.1	<i>Modalidades de Biossinais Abordadas</i>	<i>13</i>
3.2.2	<i>Biossinais e LLMs: Estado Atual</i>	<i>13</i>
3.2.3	<i>Limitações e Desafios</i>	<i>14</i>
3.3	Survey 2: Modelos de Fundação para Biossinais	15
3.3.1	<i>Heterogeneidade das Modalidades de Biossinais</i>	<i>15</i>
3.3.2	<i>Paradigma de Pré-treinamento e Adaptação</i>	<i>15</i>
3.3.3	<i>Avaliação e Benchmarking Inconsistentes</i>	<i>15</i>
3.4	Síntese das Limitações	16
4	BASE DE DADOS SELECIONADA	17
4.1	Descrição da Base de Dados	17
4.2	Justificativa e Limitações	18
5	CONSIDERAÇÕES FINAIS	19
5.1	Síntese dos Resultados	19
5.2	Perspectivas	19
	REFERÊNCIAS	20

1 INTRODUÇÃO

A análise de biossinais — sinais gerados pela atividade fisiológica do organismo humano — constitui um dos pilares da engenharia biomédica moderna. Sinais como o Eletroencefalograma (EEG), o ECG, o Eletromiograma (EMG) e a Fotopletismografia (PPG) carregam informações sobre o estado funcional do sistema nervoso central, do sistema cardiovascular e do sistema musculoesquelético. A capacidade de extrair padrões significativos a partir dessas medições é condição essencial para o desenvolvimento de sistemas de apoio ao diagnóstico, Interface Cérebro-Computador (BCI), monitores vestíveis e uma gama crescente de aplicações clínicas e de pesquisa.

A disciplina Aquisição de Biossinais propõe um percurso metodológico que parte da aquisição e do pré-processamento do sinal, com o intuito de deixar os dados prontos para aplicação de técnicas de Reconhecimento de Padrões (RP). Antes de iniciar esse *pipeline*, é necessário que a equipe conheça as ferramentas disponíveis para análise de sinais eletrofisiológicos, compreenda o panorama atual e as limitações da área, e defina a base de dados sobre a qual todo o trabalho subsequente será desenvolvido.

Com esses objetivos, o presente trabalho apresenta três contribuições articuladas:

- **Estudo da ferramenta MNE-Python:** descrição das principais estruturas de dados, capacidades de pré-processamento e recursos de análise disponíveis no pacote, com o propósito de familiarizar a equipe com o estado da arte em ferramentas abertas para análise de biossinais;
- **Panorama da área e limitações:** discussão crítica do estado atual com base em dois *surveys* recentes sobre a aplicação de LLMs e Modelos de Fundação para Biossinais (BFMs) a dados biomédicos (DING *et al.*, 2024; GU *et al.*, 2025);
- **Seleção e apresentação da base de dados:** identificação, descrição e justificativa da base de dados que será utilizada ao longo de todo o projeto da disciplina.

O trabalho foi desenvolvido em equipe, composta por José Lessa e Matheus Rocha.

1.1 Organização do Documento

O restante deste documento está organizado da seguinte forma. O Capítulo 2 descreve o pacote MNE-Python. O Capítulo 3 discute o panorama atual da área de biossinais a partir dos *surveys* selecionados. O Capítulo 4 detalha a base de dados escolhida para o projeto. Por fim, o

Capítulo 5 reúne as considerações finais.

2 FERRAMENTA MNE-PYTHON

O MNE-Python (MNE Contributors, 2024a) é um pacote de código aberto em Python para análise de dados neurofisiológicos, com foco principal em Magnetoencefalograma (MEG) e EEG. Distribuído sob licença BSD-3 e mantido por uma comunidade ativa de colaboradores, integra-se nativamente ao ecossistema científico Python — NumPy, SciPy e matplotlib — e suporta ainda modalidades como EEG de Superfície Cortical Estéreo (sEEG), Eletrocorticografia (ECoG) e Espectroscopia Funcional no Infravermelho Próximo (fNIRS) (MNE Contributors, 2024b). A versão estável atual é a **1.11.0** (MNE Contributors, 2024a).

2.1 Pipeline de Análise e Estruturas de Dados

O MNE-Python organiza o fluxo de análise em torno de quatro objetos principais, que correspondem às etapas progressivas do *pipeline*:

O objeto `Raw` representa o sinal contínuo bruto. É o ponto de entrada de qualquer análise: o pacote lê nativamente dezenas de formatos (*European Data Format* (EDF)/EDF+, BDF, FIFF, SET, CNT, entre outros), tornando-o compatível com a maioria dos equipamentos de aquisição. Junto ao sinal, o `Info` armazena metadados essenciais como taxa de amostragem, nomes dos canais e montagem de eletrodos. Os **eventos** são marcadores temporais embutidos no `Raw` que indicam quando algo de interesse ocorreu durante a gravação — um estímulo, uma resposta ou uma anotação experimental. Eles são a ponte entre o sinal contínuo e a segmentação.

O objeto `Epochs` é criado a partir dos eventos: recorta janelas do sinal contínuo ao redor de cada marcador, formando um conjunto de segmentos que podem ser analisados individualmente ou em média.

O objeto `Evoked` resulta da média das épocas por condição experimental, representando o potencial evocado médio — estrutura central em análises de Potencial Relacionado a Evento (ERP).

Por fim, o objeto `SourceEstimate` armazena a atividade estimada nas fontes corticais após a solução do problema inverso, associando cada instante de tempo a um valor de ativação em cada vértice do espaço cortical. É utilizado em análises avançadas de localização de fontes, que vão além do escopo deste trabalho.

2.2 Pré-processamento

O MNE-Python cobre as etapas convencionais de limpeza do sinal. A **filtragem** oferece filtros passa-banda, passa-alta, passa-baixa e notch nos domínios Resposta ao Impulso Finita (FIR) e Resposta ao Impulso Infinita (IIR). O **referenciamento** permite configurar a referência do EEG para média global, eletrodo específico ou mastoides. Canais com má qualidade podem ser marcados e **interpolados** a partir dos canais vizinhos.

Para **remoção de artefatos**, o pacote oferece dois métodos principais: a Análise de Componentes Independentes (ICA), com os algoritmos FastICA e Picard, que identifica e remove componentes de artefatos oculares, cardíacos e musculares; e o SSP (*Signal Space Projection*), alternativa mais direta voltada especialmente para supressão de ruídos sistemáticos em MEG.

2.3 Visualização

A visualização é um ponto forte do MNE-Python. O método `raw.plot()` exibe o sinal contínuo em uma janela interativa que permite navegar no tempo, marcar canais ruins e anotar trechos problemáticos. O `epochs.plot()` mostra todas as épocas sobrepostas, facilitando a rejeição visual de segmentos ruidosos. Para dados evocados, `evoked.plot_joint()` combina a série temporal de todos os canais com mapas topográficos nos instantes de pico, e `plot_topomap()` exibe a distribuição espacial da atividade no couro cabeludo em um instante específico.

2.4 Análise Espectral e Decodificação

Para análise em frequência, o objeto `Spectrum` computa a Densidade Espectral de Potência (PSD) via Welch ou multitaper. A análise tempo-frequência é feita com wavelets de Morlet ou STFT, retornando representações de potência por canal, frequência e tempo.

Para **decodificação**, o módulo `mne.decoding` disponibiliza estimadores compatíveis com o scikit-learn que operam diretamente sobre objetos `Epochs`. O mais utilizado é o CSP (*Common Spatial Pattern*), amplamente adotado em tarefas de imaginação motora. Esses estimadores podem ser usados em *pipelines* scikit-learn com validação cruzada e qualquer classificador disponível na biblioteca.

Em resumo, o MNE-Python oferece um ambiente completo para o trabalho com biossinais eletrofisiológicos — da leitura do arquivo bruto até a classificação por aprendizado de

máquina — sem necessidade de ferramentas externas para as etapas centrais do *pipeline*. Para o contexto deste projeto, o estudo da ferramenta é relevante por apresentar um panorama completo das capacidades disponíveis em pacotes abertos para análise de biossinais eletrofisiológicos, servindo de referência para decisões metodológicas nas etapas subsequentes da disciplina.

3 PANORAMA DA ÁREA E LIMITAÇÕES IDENTIFICADAS

A consolidação de métodos de aprendizado de máquina e, mais recentemente, de BFMs aplicados a biossinais representa um dos campos mais dinâmicos da engenharia biomédica computacional. Apesar do crescimento expressivo de publicações, a literatura especializada identifica um conjunto persistente de desafios que limitam a transferência dessas abordagens para cenários clínicos reais. Este capítulo discute essas limitações com base em dois *surveys* de referência: Ding *et al.* (2024), sobre LLMs em biossinais, e Gu *et al.* (2025), sobre modelos de fundação para biossinais.

3.1 Contexto: Biossinais e Inteligência Artificial

A longevidade crescente da população global tem elevado a demanda por sistemas de monitoramento contínuo de saúde e detecção precoce de condições patológicas. Conforme apontado por Ding *et al.* (2024), a maior parte das pesquisas existentes tende a se concentrar em modalidades de sensores específicas, sem explorar plenamente a integração com modelos de inteligência artificial mais avançados.

O advento dos LLMs — modelos baseados em *transformers* com bilhões de parâmetros, pré-treinados em grandes corpora de texto — abriu possibilidades para a interpretação de biossinais em linguagem natural, geração de laudos automáticos e análise *zero-shot* de dados clínicos. Paralelamente, os BFMs buscam replicar esse sucesso operando diretamente sobre séries temporais fisiológicas brutas (GU *et al.*, 2025).

3.2 Survey 1: LLMs em Aplicações de Biossinais

O trabalho de Ding *et al.* (2024) parte de uma observação simples: os LLMs já demonstraram resultados expressivos em diversas áreas — modelos como MedPaLM-2 e Med-Prompt alcançam acurácias de 86,5% e 90,2%, respectivamente, em questões do exame de licenciamento médico norte-americano (USMLE), sendo que o MedPrompt supera o desempenho médio de especialistas humanos (87,0%). No entanto, essa evolução não se refletiu de forma sistemática no domínio dos biossinais: a maioria das pesquisas ainda se concentra em modalidades isoladas e raramente explora o potencial dos LLMs para análise de sinais fisiológicos. O survey busca mapear o estado atual dessa integração, identificando o que já foi feito e os obstáculos que ainda precisam ser superados.

3.2.1 Modalidades de Biossinais Abordadas

O survey cobre quatro modalidades principais. O **ECG** registra a atividade elétrica do coração e é amplamente utilizado no diagnóstico de arritmias, infartos e fibrilação atrial. É a modalidade mais explorada com LLMs, com aplicações que vão de geração automática de laudos a sistemas de resposta a perguntas clínicas. A **PPG** mede variações no volume de sangue arterial por sensores ópticos, sendo o sinal predominante em dispositivos vestíveis como *smartwatches*. Permite estimar frequência cardíaca, saturação de oxigênio e pressão arterial, mas é altamente suscetível a artefatos de movimento e variações de sensor. O **EEG** capta a atividade elétrica cerebral e se organiza em bandas de frequência com significados funcionais distintos — delta (sono profundo), teta (memória), alfa (relaxamento), beta (atenção) e gama (processamento sensorial) — sendo utilizado em diagnóstico de epilepsia, estadiamento do sono, reconhecimento de emoções e BCI. Por fim, a **Unidade de Medição Inercial (IMU)** combina acelerômetro e giroscópio para capturar movimento corporal, com aplicações em reconhecimento de atividade humana (HAR), análise de marcha e detecção de quedas.

A Tabela 1 sintetiza as características de cada modalidade.

Tabela 1 – Resumo das quatro modalidades de biossinais abordadas pelo survey de Ding *et al.* (2024).

Sinal	O que mede	Aplicações clínicas	Uso com LLMs
ECG	Atividade elétrica cardíaca	Arritmias, infarto, fibrilação atrial	Laudos automáticos, QA, <i>zero-shot</i>
PPG	Volume de sangue arterial	FC, SpO ₂ , PA, estresse	GPT-PPG, agentes conversacionais
EEG	Atividade elétrica cerebral	Epilepsia, sono, emoção, BCI	Classificação <i>few-shot</i> , EEG-to-Text
IMU	Aceleração e orientação	HAR, marcha, quedas, tremores	<i>Zero-shot</i> HAR, dados sintéticos

Fonte: Elaborado pelos autores com base em Ding *et al.* (2024).

3.2.2 Biossinais e LLMs: Estado Atual

A aplicação de LLMs a biossinais exige estratégias de adaptação, já que esses modelos foram treinados em texto e não em séries temporais numéricas. As abordagens mais comuns consistem em converter o sinal em imagem (como espectrogramas ou gráficos), representá-lo como texto ou treinar um codificador específico para projetar o sinal em um espaço compatível com o LLM.

Os resultados obtidos até o momento são heterogêneos. No ECG, o GPT-4 sem

contexto clínico acertou apenas 19% das interpretações, valor que sobe para 45% quando informações clínicas são fornecidas — ainda aquém de cardiologistas experientes. No EEG, o modelo EEG-GPT alcançou desempenho competitivo utilizando apenas 2% dos dados de treinamento, indicando que LLMs podem compensar parcialmente a escassez de anotações. Já no IMU, o GPT-4 sem preparo específico produziu respostas corretas em apenas 16% das tentativas, mas abordagens com codificadores intermediários e geração de dados sintéticos (como o pipeline IMUGPT) mostraram resultados mais promissores.

3.2.3 Limitações e Desafios

Apesar dos avanços, o survey aponta limitações estruturais que ainda impedem a consolidação do campo.

Escassez de dados anotados. Diferentemente de Processamento de Linguagem Natural (NLP) ou visão computacional — onde existem bases com milhões de exemplos rotulados —, a coleta de biossinais anotados de forma clinicamente confiável é custosa e demorada. Além disso, a literatura permanece fragmentada em modalidades isoladas, sem explorar a integração multimodal de forma sistemática.

Falta de *benchmarks* padronizados. Cada trabalho define seus próprios conjuntos de dados, divisões treino-teste e métricas, tornando a comparação entre abordagens praticamente inviável. Em domínios mais maduros, como NLP, a existência de *benchmarks* unificados como o GLUE foi determinante para acelerar o progresso — equivalente ainda inexistente para biossinais.

Interpretabilidade e alucinações. LLMs operam como caixas-pretas, e seus mecanismos de decisão raramente se traduzem em conceitos fisiológicos reconhecíveis por profissionais de saúde. Mais grave ainda, o survey documenta ocorrências de alucinações em tarefas de interpretação de ECG com o GPT-4, em que o modelo gera saídas plausíveis mas clinicamente incorretas. Em contextos médicos, esse comportamento representa um risco direto ao paciente.

Privacidade, viés e generalização. Dados fisiológicos são sensíveis, criando barreiras regulatórias ao compartilhamento entre instituições. Além disso, modelos treinados em populações homogêneas tendem a não generalizar bem para outros grupos. O survey aponta a PPG como caso exemplar: o sinal é afetado pelo tom de pele do usuário, o que pode introduzir vieses sistemáticos em modelos treinados sem diversidade demográfica adequada.

Custo computacional. Os LLMs de estado da arte demandam recursos incompatíveis com as restrições de dispositivos vestíveis. Viabilizar inferência em tempo real nesses

ambientes exige técnicas de compressão como quantização e destilação de conhecimento, ainda pouco exploradas especificamente para biossinais.

Em síntese, embora os LLMs apresentem potencial relevante para o domínio dos biossinais, os resultados atuais são ainda preliminares. O campo está em formação, e os trabalhos analisados representam mais provas de conceito do que evidências consolidadas de utilidade clínica.

3.3 Survey 2: Modelos de Fundação para Biossinais

O *survey* de Gu *et al.* (2025) analisa o estado da arte em BFM, identificando três direções convergentes: (i) treinamento sobre grandes corpora de biossinais; (ii) adaptação de modelos de séries temporais ao domínio biomédico; e (iii) uso de LLMs multimodais para interpretação de biossinais.

3.3.1 Heterogeneidade das Modalidades de Biossinais

Uma diferença fundamental entre biossinais e dados de linguagem é a heterogeneidade de modalidades, frequências de amostragem e montagens de eletrodos. Um modelo de EEG treinado com o sistema 10-20 pode não generalizar para dados coletados com outra montagem. Esse problema — referido como desafio de *topology-agnosticism* — é um dos principais obstáculos para BFM universais.

3.3.2 Paradigma de Pré-treinamento e Adaptação

Diferentemente de modelos de linguagem que se beneficiam de décadas de texto digitalizado disponível, biossinais de qualidade laboratorial são escassos. Estratégias de auto-supervisão (reconstrução de segmentos mascarados, predição temporal, contrastividade de representações) têm se mostrado promissoras, mas ainda não alcançam a robustez observada em modelos de linguagem. A aceleração de publicações sobre BFM para EEG só se tornou expressiva a partir de 2023, com modelos como BIOT, BrainBERT e Brant (GU *et al.*, 2025).

3.3.3 Avaliação e Benchmarking Inconsistentes

Gu *et al.* (2025) ressaltam que a comparação entre modelos é dificultada pela diversidade de conjuntos de dados, divisões treino-teste e métricas utilizadas nos trabalhos

publicados.

3.4 Síntese das Limitações

A Tabela 2 consolida as principais limitações identificadas nos dois *surveys* revisados.

Tabela 2 – Síntese das principais limitações da área de biossinais identificadas nos *surveys*.

Limitação	Descrição	Referência
Escassez de dados anotados	Custo elevado de coleta e anotação especializada	Ding <i>et al.</i> (2024)
Fragmentação por modalidade	Foco em modalidades isoladas sem integração	Ding <i>et al.</i> (2024)
Falta de benchmarks	Comparação entre trabalhos dificultada	Ding <i>et al.</i> (2024), Gu <i>et al.</i> (2025)
Interpretabilidade	Modelos caixa-preta inadequados ao contexto clínico	Ding <i>et al.</i> (2024)
Generalização inter-sujeito	Alta variabilidade biológica entre indivíduos	Gu <i>et al.</i> (2025)
Heterogeneidade de montagens	Modelos não generalizam para diferentes configurações	Gu <i>et al.</i> (2025)

Fonte: Elaborado pelos autores.

4 BASE DE DADOS SELECIONADA

A base de dados escolhida para o projeto é a **PTB-XL**, disponível gratuitamente na plataforma PhysioNet sob licença Creative Commons Attribution 4.0 (WAGNER *et al.*, 2020; GOLDBERGER *et al.*, 2000). A escolha foi motivada principalmente pela escala da base e pela qualidade das anotações clínicas.

4.1 Descrição da Base de Dados

A PTB-XL foi desenvolvida pelo Physikalisch-Technische Bundesanstalt (PTB) em parceria com o Helios Klinikum de Berlim, com dados coletados entre 1989 e 1996 e publicados em 2020 no periódico *Scientific Data* (WAGNER *et al.*, 2020). A base está disponível em:

<https://physionet.org/content/ptb-xl/1.0.3/>

São ao todo **21.799 registros de ECG** de 10 segundos obtidos de **18.869 pacientes**, coletados com equipamento clínico padrão de 12 derivações. Cada registro foi anotado por até dois cardiologistas de forma independente, com nível de confiança associado a cada diagnóstico. As anotações cobrem **71 classes diagnósticas** agrupadas em cinco superclasses, conforme a Tabela 3. Um mesmo registro pode receber mais de um diagnóstico, permitindo experimentos tanto de classificação multiclasse quanto multirrotulo.

Tabela 3 – Superclasses diagnósticas da PTB-XL e número aproximado de registros por categoria (WAGNER *et al.*, 2020).

Superclasse	Descrição	Registros
NORM	Ritmo sinusal normal	≈9.500
MI	Infarto do miocárdio	≈5.500
STTC	Alterações de segmento ST e onda T	≈5.250
CD	Distúrbios de condução	≈4.900
HYP	Hipertrofia ventricular ou atrial	≈2.650

Fonte: Adaptado de Wagner *et al.* (2020).

Os arquivos são disponibilizados no formato WFDB, compatível com as bibliotecas Python wfdb e neurokit2, e os metadados clínicos — incluindo idade, sexo, peso e dispositivo de aquisição — são fornecidos em arquivos CSV. Os registros estão disponíveis em duas taxas de amostragem: 500 Hz (alta resolução) e 100 Hz (versão reduzida, mais comum em experimentos de aprendizado de máquina).

4.2 Justificativa e Limitações

A principal vantagem da PTB-XL em relação a alternativas mais antigas é sua escala: com quase 22.000 registros de mais de 18.000 pacientes, é uma das maiores bases públicas de ECG de 12 derivações disponível, o que responde diretamente à limitação de escassez de dados apontada nos *surveys* revisados. Além disso, a presença de metadados demográficos completos permite avaliar generalização inter-sujeito e possíveis vieses por sexo ou faixa etária — aspectos discutidos no Capítulo 3 e raramente contemplados em bases mais antigas.

No entanto, a base apresenta algumas limitações relevantes: os registros têm apenas 10 segundos de duração, o que inviabiliza análises de eventos arrítmicos prolongados; há desbalanceamento entre as superclasses, com NORM representando cerca de 43% dos registros; e os dados foram coletados em um único centro alemão, o que pode limitar a generalização para outras populações.

5 CONSIDERAÇÕES FINAIS

Este trabalho cumpriu os três objetivos propostos para a etapa introdutória do projeto da disciplina Aquisição de Biossinais.

5.1 Síntese dos Resultados

Ferramenta MNE-Python. O Capítulo 2 apresentou o MNE-Python como uma das principais ferramentas abertas para análise de sinais eletrofisiológicos. Suas quatro estruturas de dados fundamentais — Raw, Epochs, Evoked e SourceEstimate — organizam o sinal de forma coerente ao longo de todo o *pipeline* de análise. As capacidades de filtragem, ICA, referenciamento, análise espectral e decodificação via scikit-learn cobrem praticamente todas as etapas metodológicas previstas ao longo da disciplina.

Limitações da área de biossinais. A revisão dos *surveys* selecionados (Capítulo 3) revelou um panorama em que os avanços técnicos com LLMs e BFM s coexistem com limitações estruturais persistentes: escassez de dados anotados de qualidade, falta de *benchmarks* padronizados, desafios de interpretabilidade, variabilidade inter-sujeito e barreiras à implantação clínica.

Base de dados selecionada. A PTB-XL (Capítulo 4), disponível no PhysioNet, foi selecionada com base em critérios objetivos: acesso público, tamanho e diversidade adequados, anotações confiáveis, relevância para classificação de condições cardíacas e documentação científica de qualidade. Com mais de 18.000 pacientes e 22.000 registros de ECG, o conjunto oferece um ponto de partida sólido para o *pipeline* de pré-processamento da disciplina.

5.2 Perspectivas

Nas etapas subsequentes, a equipe dará continuidade ao *pipeline* de pré-processamento sobre o PTB-XL, contemplando avaliação por Índice de Qualidade do Sinal (SQI), análise estatística inicial, limpeza e correção dos dados, segmentação por janelamento, extração de atributos nos domínios do tempo, frequência e tempo-frequência, engenharia de *features*, redução de dimensionalidade, seleção de atributos e, ao final, a validação estatística do conjunto de dados para posterior aplicação de técnicas de RP.

REFERÊNCIAS

DING, C.; WU, C.; CHEN, Z.; NI, J. A survey of LLMs on biosignal applications. **TechRxiv**, nov 2024. Disponível em: <<https://www.techrxiv.org/users/852956/articles/1238676>>. Acesso em: mar. 2026.

GOLDBERGER, A. L.; AMARAL, L. A. N.; GLASS, L.; HAUSDORFF, J. M.; IVANOV, P. C.; MARK, R. G.; MIETUS, J. E.; MOODY, G. B.; PENG, C.-K.; STANLEY, H. E. PhysioBank, PhysioToolkit, and PhysioNet: components of a new research resource for complex physiologic signals. **Circulation**, v. 101, n. 23, p. e215–e220, 2000.

GU, X. *et al.* Foundation models for biosignals: a survey. **TechRxiv**, 2025. Disponível em: <<https://www.techrxiv.org/users/953631/articles/1322825>>. Acesso em: mar. 2026.

MNE Contributors. **MNE-Python: open-source MEG and EEG data analysis**. 2024a. Versão 1.11.0. Disponível em: <<https://mne.tools/stable/>>. Acesso em: mar. 2026.

MNE Contributors. **Overview of the MNE tools suite**. 2024b. Disponível em: <https://mne.tools/stable/install/mne_tools_suite.html>. Acesso em: mar. 2026.

WAGNER, P.; STRODTHOFF, N.; BOUSSELJOT, R.-D.; KREISELER, D.; LUNZE, F. I.; SAMEK, W.; SCHAEFFTER, T. PTB-XL, a large publicly available electrocardiography dataset. **Scientific Data**, v. 7, n. 1, p. 154, 2020.